

SEMINAR PROPOSAL



PERFORMA LSTM DALAM PREDIKSI KESALAHAN PERAMALAN HARGA EMAS PADA METODE SARIMA

I NYOMAN BAGUS ADITYA ADNYANA
NIM. 2301010347

Dosen Pembimbing I
Made Leo Radhitya, S.Kom., M.Cs.

Dosen Pembimbing II
Ni Putu Eka Kherismawati, S.Pd., M.M.,

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNOLOGI DAN INFORMATIKA
INSTITUT BISNIS DAN TEKNOLOGI INDONESIA
DENPASAR 2026

KATA PENGANTAR

Puji syukur penulis panjatkan kepada Tuhan Yang Maha Esa, karena berkat rahmat-Nya Proposal dengan judul Performa LSTM dalam prediksi kesalahan peramalan harga emas pada metode SARIMA dapat diselesaikan.”

Penulis menyadari dalam menyelesaikan laporan Proposal ini tidak terlepas dari berbagai pihak yang telah membantu dalam membimbing dan membantu baik secara moral, materi, dan ilmu pengetahuan. Untuk itu penulis menyampaikan terimakasih kepada :

1. Bapak Dr. I Dewa Made Krishna Muku, M.T., sebagai Rektor Institut Bisnis dan Teknologi Indonesia.
2. Bapak Dr. Komang Kurniawan Widiartha, M.Cs., sebagai Dekan Fakultas Teknologi dan Informatika.
3. Bapak I Gusti Agung Indrawan, S.T., M.T., sebagai Koordinator Program Studi Informatika Institut Bisnis dan Teknologi Indonesia.
4. Bapak Made Leo Radhitya, S.Kom., M.Cs., sebagai Dosen Pembimbing I.
5. Ibuk Ni Putu Eka Kherismawati, S.Pd., M.M., sebagai Dosen Pembimbing II.

Untuk itu kritik dan saran dari semua pihak untuk penyempurnaan sangat penulis hargai.

Denpasar, 6 Juli 2026

Penulis

DAFTAR ISI

Judul	i
KATA PENGANTAR	ii
DAFTAR ISI.....	iii
DAFTAR TABEL	vii
DAFTAR GAMBAR	viii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Batasan Masalah.....	4
1.4 Tujuan Penelitian.....	4
1.5 Manfaat Penelitian.....	5
1.6 Sistematika Penulisan.....	5
BAB II TINJAUAN PUSTAKA	6
2.1 Penelitian Terdahulu	6
2.2 Peramalan Deret Waktu (<i>Time Series Forecasting</i>)	9
2.2.1 Pengertian Peramalan (<i>Forecasting</i>).....	9
2.2.2 Jenis-jenis Peramalan.....	9
2.2.3 Metode Peramalan	10
2.2.4 Peran Peramalan dalam Keuangan.....	11
2.3 Harga Emas sebagai Objek Penelitian.....	11
2.3.1 Pengertian Emas sebagai Aset	11
2.3.2 Karakteristik Harga Emas	11
2.3.3 Faktor yang Mempengaruhi Harga Emas	12
2.4 <i>Seasonal Autogressive Integrated Moving Average</i> (SARIMA)	12
2.4.1 Model <i>Autogressive</i> (AR)	12
2.4.2 Model <i>Moving Average</i> (MA).....	13
2.4.3 Model <i>Autogressive Moving Average</i> (ARMA).....	13
2.4.4 Model <i>Autogressive Integrated Moving Average</i> (ARIMA)	13
2.4.5 Model <i>Seasonal Autogressive Moving Average</i> (SARMA).....	14
2.4.6 Model <i>Seasonal Autogressive Integrated Moving</i> <i>Average</i> (SARIMA)	14

2.4.7	Pengertian ARIMA dan SARIMA.....	15
2.4.8	Persamaan Umum SARIMA	16
2.4.9	Komponen Model SARIMA	16
2.4.10	Kelebihan dan Keterbatasan SARIMA.....	17
2.5	Residual dalam Peramalan	17
2.5.1	Pengertian Residual	18
2.5.2	Konsep White Noise.....	18
2.5.3	Residual sebagai informasi Tambahan	19
2.6	<i>Long Short-Term Memory</i> (LSTM)	19
2.6.1	Arsitektur LSTM	20
2.7	Model <i>Hybrid</i> SARIMA-LSTM	21
2.7.1	Konsep Model <i>Hybrid</i>	21
2.7.2	Mekanisme SARIMA-LSTM	21
2.7.3	Keunggulan Model <i>Hybrid</i>	22
2.8	Evaluasi Model Peramalan.....	22
2.8.1	<i>Mean Absolute Error</i> (MAE).....	22
2.8.2	<i>Root Mean Squared Error</i> (RMSE).....	22
2.8.3	<i>Mean Squared Error</i> (MSE).....	23
2.8.4	<i>Mean Absolute Percentage Error</i> (MAPE)	23
BAB III	ANALISIS DAN PERANCANGAN	25
3.1	Tempat dan Waktu Penelitian	25
3.2	Teknik Pengumpulan Data.....	25
3.3	Eksplorasi Data dan Analisis Harga Emas	26
3.3.1	Adanya Tren Kenaikan Jangka Panjang (<i>Long-term Upward Trend</i>)	27
3.4	Alur Penelitian	27
3.4.1	Studi Literatur.....	28
3.4.2	Analisis Data	29
3.4.3	Persiapan Data	29
3.5	Prosedur Pemodelan SARIMA-LSTM	30
3.5.1	Penerapan Metode Sliding Window	31
3.5.2	Pemodelan Linier (SARIMA).....	33
3.5.3	Pemodelan Residual (LSTM)	36
3.6	Perhitungan Manual Model SARIMA-LSTM	39
3.6.1	Tahap I Perhitungan Komponen Linear dengan Model SARIMA.....	40

3.6.2	Tahap II Perhitungan Komponen Non-Linear dengan LSTM	42
3.6.3	Tahap III Integrasi Prediksi Akhir Hybrid	43
3.7	Tahap Pengujian dan Evaluasi	44
DAFTAR PUSTAKA		46
BIODATA PENULIS		52

DAFTAR TABEL

Tabel 2. 1 Perbandingan Penelitian.....	7
Tabel 2. 2 Perbandingan Penelitian.....	8
Tabel 3. 1 Seleksi Model SARIMA	35
Tabel 3. 2 Hasil Optimasi Hyperparameter LSTM	38
Tabel 3. 3 Arsitektur LSTM.....	39
Tabel 3. 4 Pengujian Hidden Units LSTM.....	45
Tabel 3. 5 Kinerja Model	45

DAFTAR GAMBAR

Gambar 2. 2 Pemodelan LSTM	19
Gambar 2. 3 <i>Forget Gate</i>	20
Gambar 2. 4 <i>Input Gate</i>	20
Gambar 2. 5 <i>Output Gate</i>	21
Gambar 3. 1 Website Yahoo Finance (Data Harga Emas GC=F)	25
Gambar 3. 2 Data Sekunder Mentah Harga Emas file CSV	26
Gambar 3. 3 Data Historis Harga Emas Periode 2020-2025	26
Gambar 3. 4 Diagram Alur Penelitian	28
Gambar 3. 5 Alur pemodelan SARIMA-LSTM	31
Gambar 3. 6 Visualisasi Sliding Window	32
Gambar 3. 7 Model SARIMA.....	35
Gambar 3. 8 Model Residual LSTM.....	38

HALAMAN INI SENGAJA DIKOSONGKAN

BAB I

PENDAHULUAN

1.1 Latar Belakang

Peramalan deret waktu (*time series forecasting*) telah menjadi komponen fundamental dalam pengambilan keputusan berbasis data selama lima tahun terakhir. Metode ini membantu organisasi dan pemerintah memahami pola historis serta memperkirakan kondisi masa depan secara lebih sistematis. Kemampuan untuk mengukur ketidakpastian masa depan memberi dasar analitis bagi pembuat kebijakan dan manajer bisnis dalam merumuskan strategi yang adaptif terhadap dinamika pasar, perubahan ekonomi, serta gangguan eksternal. Pendekatan berbasis peramalan juga membantu meningkatkan efisiensi dalam alokasi sumber daya dan perencanaan operasional (Lubis dan Syahputra, 2022). Penerapannya terus berkembang di berbagai sektor. Sektor publik memanfaatkannya untuk mendukung intervensi kebijakan kemiskinan (Mukmin dkk., 2022). Sektor pariwisata menggunakannya untuk memproyeksikan pendapatan daerah (PUTRI dkk., 2021). Sektor kesehatan menerapkannya untuk memantau dan mengelola dinamika pandemi COVID-19 (Hendrawan dkk., 2021).

Khusus dalam sektor keuangan dan investasi, akurasi prediksi menjadi krusial. Strategi masuk-keluar pasar saham dan keputusan beli-jual aset sangat bergantung pada prakiraan tren masa depan. Seperti yang ditunjukkan oleh (Widiputra dkk., 2021), penerapan model prediksi pada harga saham korporasi (seperti BBKA) atau Indeks BEI dapat membantu investor memitigasi risiko. Hal ini sangat relevan dengan komoditas bernilai tinggi seperti emas, yang pergerakan harganya sering kali fluktuatif dan dipengaruhi oleh sentimen global.

Dalam praktik peramalan deret waktu, model statistik klasik seperti *Seasonal Autoregressive Integrated Moving Average* (SARIMA) masih menjadi standar emas dan banyak digunakan selama periode 2020–2025 (Agaal dkk., 2025). SARIMA diminati karena strukturnya yang parsimoni (sederhana), kemampuannya menangkap pola musiman secara eksplisit, dan kemudahannya dalam interpretasi komponen autoregresif serta *moving average* (Arumugam dan Natarajan, 2023) (Wizsa dkk., 2022). Ketersediaan perangkat lunak yang luas R, Python Statsmodels

menjadikan SARIMA mudah diakses untuk replikasi dan validasi (Atmanegara, 2022).

Namun, model SARIMA memiliki keterbatasan mendasar, yaitu asumsi linearitas dalam proses pemodelannya. Model ini membangun prediksi sebagai kombinasi linier dari pengamatan masa lalu dan komponen error, sehingga sering kali kurang mampu menangkap dinamika nonlinier yang kompleks, lonjakan tiba-tiba atau *spikes*, maupun perubahan pola yang tidak stabil pada data deret waktu (Arumugam dan Natarajan, 2023) (Li dan Yang, 2023).

Beberapa studi terbaru menunjukkan bahwa meskipun proses identifikasi model, seleksi ordo, dan pengujian diagnostik telah dilakukan secara cermat, hasil peramalan menggunakan SARIMA masih dapat menghasilkan residual yang signifikan serta tidak sepenuhnya memenuhi asumsi *white noise* (Park dan Yang, 2024) (Medugu dkk., 2025). Hal ini menunjukkan bahwa masih terdapat informasi yang belum sepenuhnya dimodelkan oleh pendekatan linier, sehingga diperlukan metode tambahan yang mampu menangkap pola nonlinier pada residual tersebut.

Residual yang dihasilkan SARIMA sering kali masih mengandung pola terstruktur yang gagal ditangkap oleh model linier tersebut. Beberapa penyebab utamanya meliputi kegagalan menangkap anomali ekstrem (Singh dkk., 2024), adanya pergeseran struktur akibat kejadian luar biasa seperti pandemi atau krisis ekonomi (Xian dkk., 2023), serta pengaruh variabel eksogen non-linier (Pimentel dkk., 2024). Jika pola non-linier dalam residual ini diabaikan, akurasi peramalan akan menurun secara signifikan, seperti yang dibuktikan oleh peningkatan kesalahan prediksi *Root Mean Squared Error* atau *Mean Absolute Percentage Error* (RMSE/MAPE) pada berbagai studi kasus (Sirisha dkk., 2022).

Untuk mengatasi keterbatasan model linier, metode *Deep Learning* seperti *Long Short-Term Memory* (LSTM) menawarkan solusi yang menjanjikan. Sebagai varian dari *Recurrent Neural Network* (RNN), LSTM dirancang khusus untuk menangkap ketergantungan jangka panjang dan mengaproksimasi fungsi non-linier yang kompleks tanpa memerlukan rekayasa fitur manual yang rumit (Liang dkk., 2024) (Abbasimehr dkk., 2022). Mekanisme gerbang (*gating*) pada LSTM

memungkinkannya mengatasi masalah *vanishing gradient* dan secara dinamis mempelajari pola historis yang relevan.

Pendekatan hibrida yang menggabungkan SARIMA dan LSTM muncul sebagai metode yang efektif untuk meningkatkan akurasi. Dalam skema ini, SARIMA digunakan untuk memodelkan komponen linier atau tren dan musiman, sementara LSTM difungsikan sebagai korektor kesalahan untuk memodelkan residual non-linier yang dihasilkan SARIMA. Berbagai studi empiris, seperti pada peramalan pariwisata (Wu dkk., 2021), (Li dan Yang, 2023), dan harga minyak (Lee dkk., 2024), menunjukkan bahwa memodelkan residual dengan LSTM dapat menurunkan tingkat kesalahan (RMSE/MAE) sebesar 10% hingga 30% dibandingkan model tunggal.

Meskipun potensi hibridisasi ini besar, terdapat kesenjangan penelitian (*research gap*) yang signifikan. Mayoritas studi hibrida saat ini hanya berfokus pada peningkatan akurasi akhir model secara agregat, tanpa melakukan evaluasi mendalam terhadap performa LSTM secara spesifik dalam memprediksi kesalahan (residual) itu sendiri (Abdulkadir dkk., 2023), (H. Chen dkk., 2023). Penggunaan LSTM sebagai model koreksi kesalahan pada data finansial, khususnya harga emas masih sangat terbatas dibandingkan dengan bidang energi atau meteorologi. Selain itu, belum banyak literatur yang secara kuantitatif membedah seberapa efektif LSTM mengurangi struktur non-linier pada residual SARIMA melalui metrik evaluasi residual yang terpisah.

Oleh karena itu, penelitian ini bermaksud untuk mengisi kesenjangan tersebut dengan menganalisis secara spesifik performa LSTM dalam memprediksi kesalahan peramalan (residual) pada metode SARIMA, dengan studi kasus pada harga emas. Penelitian ini diharapkan dapat memberikan wawasan baru mengenai efektivitas strategi koreksi kesalahan non-linier dalam meningkatkan akurasi peramalan finansial.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah di uraikan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

Bagaimana efektivitas pengintegrasian model *Long Short-Term Memory* (LSTM) dalam memprediksi pola kesalahan (residual) non-linier yang dihasilkan oleh model SARIMA guna meningkatkan akurasi peramalan harga emas dibandingkan dengan penggunaan model tunggal?

1.3 Batasan Masalah

Agar penelitian tetap fokus dan tidak bias, batasan-batasan berikut perlu ditetapkan:

1. Data Penelitian: Menggunakan data historis harga emas dunia dalam rentang waktu diambil dari periode 2020-2025.
2. Metode Statistik: Model linier terbatas pada penggunaan SARIMA (*Seasonal Autoregressive Integrated Moving Average*).
3. Metode *Deep Learning*: Model non-linier terbatas pada arsitektur LSTM (*Long Short-Term Memory*) yang difungsikan khusus untuk memproses residual.
4. Indikator Evaluasi: Kinerja model akan diukur menggunakan metrik *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan *Mean Absolute Percentage Error* (MAPE).
5. Fokus Analisis: Penelitian ini menitikberatkan pada kemampuan LSTM dalam menangkap pola pada residual, bukan pada optimasi *hyperparameter* LSTM secara luas untuk data mentah.

1.4 Tujuan Penelitian

Penelitian ini bertujuan untuk mengintegrasikan model statistik SARIMA dan algoritma *deep learning* LSTM ke dalam satu pendekatan hibrida guna meningkatkan akurasi peramalan harga emas, yang dilakukan dengan cara menganalisis efektivitas SARIMA dalam menangkap komponen tren linier dan pola musiman, mengevaluasi kemampuan spesifik LSTM dalam memodelkan pola residual non-linier yang dihasilkan dari sisaan model statistik tersebut, serta memvalidasi efisiensi penggabungan keduanya untuk menghasilkan performa prediksi yang lebih akurat dibandingkan dengan penggunaan model tunggal tradisional.

1.5 Manfaat Penelitian

Adapun manfaat yang dapat diambil dari penelitian ini adalah sebagai berikut:

1. pada literatur model deret waktu hibrida, khususnya mengenai efektivitas mekanisme koreksi kesalahan (*error correction mechanism*) berbasis *Deep Learning* terhadap model statistik klasik pada data keuangan.
2. Pengembangan Teknologi menunjukkan potensi implementasi algoritma *Long Short-Term Memory* (LSTM) dalam menangkap pola non-linier yang kompleks pada residual peramalan, sehingga dapat menjadi referensi dalam pengembangan sistem pendukung keputusan (DSS) yang lebih cerdas.
3. Pemecahan Persoalan Pembangunan dan Ekonomi: Membantu para pelaku pasar, investor, dan pengambil kebijakan dalam memitigasi risiko akibat fluktuasi harga emas melalui prediksi yang lebih akurat, yang pada akhirnya mendukung stabilitas perencanaan keuangan dan investasi nasional.
4. Pengembangan Institusi: Menambah khazanah penelitian ilmiah di lingkungan universitas terkait integrasi kecerdasan buatan dalam domain *Financial Technology* (FinTech), serta menjadi referensi bagi peneliti selanjutnya yang ingin mendalami optimasi model peramalan pada komoditas lainnya.

1.6 Sistematika Penulisan

Penulisan laporan penelitian ini dibagi menjadi lima bab, yaitu:

BAB I PENDAHULUAN

Mengulas tentang latar belakang, masalah, batasan masalah, tujuan, manfaat, dan sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Pada bab ini mengulas tentang penelitian serupa yang pernah dilakukan serta teori-teori terkait *usability* dan perancangan *website*

BAB III ANALISIS DAN PERANCANGAN

Pada bab ini mengulas mengenai metode yang dilakukan selama proses penelitian, mulai dari pengumpulan data, perancangan.

BAB II TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Kajian terhadap beberapa penelitian terdahulu yang relevan dilakukan guna mendukung penelitian ini. Kajian ini bertujuan untuk memahami arah penelitian sebelumnya, metode yang digunakan, hasil yang diperoleh, serta menemukan posisi dan perbedaan penelitian yang akan dilakukan .

Penelitian oleh (Kontopoulou dkk., 2023) menyoroti adanya pergeseran paradigma dalam metode peramalan deret waktu dari pendekatan statistik konvensional menuju model *hybrid* yang mengintegrasikan *Machine Learning*. Dalam kajian tersebut dijelaskan bahwa model ARIMA, meskipun telah lama menjadi standar industri karena kesederhanaannya, memiliki keterbatasan dalam menangani kompleksitas data dunia nyata. Hal ini disebabkan oleh asumsi linearitas yang tidak mampu merepresentasikan pola non-linier yang sering muncul pada data *modern*. Hasil penelitian ini menegaskan pentingnya penggabungan metode statistik dengan algoritma pembelajaran mesin untuk menghasilkan model peramalan yang lebih adaptif dan akurat.

Penelitian oleh (Tegar dkk., 2026) mengkaji performa model statistik dalam peramalan harga emas Indonesia dan menemukan bahwa pendekatan linier seperti SARIMA masih menghasilkan tingkat kesalahan yang relatif tinggi. Hal ini menunjukkan bahwa model linier belum mampu sepenuhnya menangkap dinamika kompleks pada data harga emas yang bersifat fluktuatif. Residual yang dihasilkan dari model tersebut masih mengandung pola tertentu yang tidak acak, sehingga mengindikasikan adanya informasi penting yang belum terakomodasi dalam proses pemodelan.

Penelitian oleh (Kashif dan Ślepaczuk, 2025) mengembangkan pendekatan *hybrid* dengan memanfaatkan residual dari model ARIMA sebagai input tambahan dalam model *Long Short-Term Memory* (LSTM) dalam menangkap pola non-linier serta ketergantungan jangka panjang pada data deret waktu. Hasil penelitian menunjukkan bahwa strategi ini mampu meningkatkan akurasi peramalan secara signifikan, karena model dapat memanfaatkan informasi yang sebelumnya tidak tertangkap oleh pendekatan linier.

Penelitian oleh (Nurhambali dkk., 2024) berfokus pada penerapan model *Long Short-Term Memory* (LSTM) dalam peramalan harga emas dengan menitikberatkan pada optimasi *hyperparameter*. Dalam penelitian tersebut dijelaskan bahwa harga emas sebagai aset *safe haven* memiliki

karakteristik data fluktuatif dan tidak stasioner. Pemilihan konfigurasi model menjadi faktor penting dalam meningkatkan performa prediksi. Hasil penelitian menunjukkan bahwa penggunaan *optimizer Adaptive Moment Estimation* (Adam) dengan *learning rate* 0,01 memberikan tingkat akurasi terbaik dalam meminimalkan kesalahan peramalan harga emas dunia.

Penelitian yang kembali dibahas dalam (Pujiarini dan Damayanti, 2025) menekankan pentingnya penggunaan pendekatan *hybrid* sebagai solusi atas keterbatasan model statistik. Simpulan dari penelitian tersebut menyatakan bahwa kombinasi antara SARIMA dan LSTM mampu meningkatkan akurasi prediksi dengan cara memisahkan komponen linier dan non-linier dalam data. *Seasonal Autoregressive Integrated Moving Average* (SARIMA) digunakan untuk menangkap pola tren dan musiman, sedangkan *Long Short-Term Memory* (LSTM) berperan dalam memodelkan residual yang masih mengandung informasi penting. Pendekatan ini memungkinkan model untuk melakukan koreksi kesalahan secara lebih efektif dibandingkan model tunggal.

Tabel 2. 1 Perbandingan Penelitian

Indikator	Penelitian		
	Penelitian I.	Penelitian II.	Penelitian III.
Penulis	(Kontopoulou dkk., 2023)	(Tegar dkk., 2026)	(Kashif dan Slepaczuk, 2025)
Topik	Pergeseran metode peramalan dari statistik ke <i>hybrid</i>	Evaluasi peforma model SARIMA pada harga emas	Pemodelan residual menggunakan pendekatan <i>hybrid</i>
Objek Penelitian	Data deret waktu umum	Harga emas Indoneisa	Data <i>time series</i> keuangan
Metode Penelitian	Arima dan integrasi <i>Machine learning</i>	SARIMA	ARIMA & LSTM (Residual sebagai input LSTM)
Hasil	Model statistik memiliki keterbatasan pada data	Model menghasilkan error cukup tinggi dan residual masih	Kombinasi model mampu meningkatkan akurasi dengan menangkap pola

	kompleks sehingga diperlukan pendekatan <i>hybrid</i> untuk meningkatkan akurasi	mengandung pola non-acak	linier dan non-linier
--	--	--------------------------	-----------------------

Tabel 2. 2 Perbandingan Penelitian

Indikator	Penelitian		
	Penelitian IV.	Penelitian V.	Yang akan dilakukan
Penulis	(Nurhambali dkk., 2024)	(Pujiarini dan Damayanti, 2025)	Penulis (2026)
Topik	Optimasi LSTM pada peramalan harga emas	Model <i>hybrid</i> untuk peningkatan faturasi peramalan	Peforma LSTM dalam memprediksi residual pada SARIMA
Objek Penelitian	Hrga emas dunia	Data deret waktu	Harga emas (<i>Gold Spot/XAUUSD</i>)
Metode Penelitian	LSTM dengan optimasi <i>hyperparameter</i>	SARIMA & LSTM (dekomposisi linier & non-linier)	SARIMA & LSTM (pemodelan residual sebagai koreksi kesalahan)
Hasil	<i>Optimizer</i> Adam (lr 0,01) memberikan hasil terbaik dalam menurunkan error prediksi	Pendekatan <i>hybrid</i> mampu menurunkan tingkat kesalahan dibanding model tunggal	

2.2 Peramalan Deret Waktu (*Time Series Forecasting*)

Peramalan merupakan kombinasi antara seni dan ilmu yang bertujuan memproyeksikan peristiwa masa depan melalui analisis data historis dan penggunaan model tertentu, yang secara umum terbagi menjadi pendekatan kuantitatif berbasis matematis serta pendekatan kualitatif yang mengandalkan intuisi subjektif. Sementara peramalan kualitatif sangat bergantung pada penilaian subjektif dan pengalaman individu, pendekatan kuantitatif menitikberatkan pada metode statistik untuk menghasilkan prediksi dari data masa lalu, di mana dalam praktiknya kedua pendekatan ini sering digabungkan dengan pertimbangan manajerial yang cermat. Beberapa metode populer yang digunakan meliputi regresi linier, *moving average*, *exponential smoothing*, hingga model ARIMA yang mengeksplorasi pola data deret waktu untuk menghasilkan prediksi jangka pendek dengan ketepatan tinggi, meskipun akurasi cenderung menurun untuk proyeksi jangka panjang. Dalam konteks pasar keuangan, penerapan metode-metode ini menjadi sangat krusial bagi investor untuk mengidentifikasi pola, tren, serta fluktuasi harga guna mengambil keputusan investasi yang lebih terinformasi dan terukur (Pujiarini dan Damayanti, 2025).

2.2.1 Pengertian Peramalan (*Forecasting*)

Untuk mengantisipasi secara akurat situasi atau kejadian di masa depan memerlukan perpaduan seni dan pengetahuan (Heizer, Jay Render dan Munson, Ummah, 2020). Penjualan dari tahun sebelumnya, dapat dipakai sebagai masukan ke dalam model matematika yang memproyeksikan angka-angka tersebut di masa depan. Ekspektasi subjektif adalah salah satu jenis perkiraan, sedangkan data yang dikumpulkan dari permintaan konsumen dan diekstrapolasi untuk mengantisipasi permintaan di masa depan adalah jenis lainnya adalah kombinasi seni dan ilmu untuk memproyeksikan apa yang akan terjadi di masa depan. Seni menggunakan intuisi dan pengalaman, sedangkan ilmu menggunakan matematik dan statistik. Peramalan dilakukan dengan tujuan menurunkan ketidakpastian dalam proses pengambilan keputusan.

2.2.2 Jenis-jenis Peramalan

Dua kategori utama peramalan adalah kualitatif dan kuantitatif. Peramalan kualitatif bergantung pada opini, pengalaman, dan intuisi, sedangkan peramalan kuantitatif menggunakan data historis dan model matematis. Dalam penelitian ini, pendekatan kuantitatif yang digunakan.

2.2.3 Metode Peramalan

Untuk menemukan pola dalam data dan membuat prediksi, regresi linier, moving average, exponential smoothing, dan ARIMA adalah beberapa metode peramalan yang umum digunakan. Metode yang dipilih bergantung pada jenis data yang digunakan.

1. Regresi linier

Regresi linier digunakan ketika terdapat hubungan kausal antara variabel dependen (yang diramalkan) dengan satu atau lebih variabel independen. Model ini mengasumsikan hubungan tersebut membentuk garis lurus. Persamaan umumnya adalah:

$$Y = a + bX$$

Keterangan:

Y : Variabel dependen (hasil ramalan),

a : Konstanta (*intercept*),

b : Kemiringan garis (*slope*),

X : Variabel independen (waktu atau faktor lain).

2. Model *Moving Avarage* (MA)

Moving Avarage adalah hubungan yang menyatakan nilai saat ini sabagai jumlah dari gangguan pada waktu sebelumnya atau tergantung nilai sebelumnya dari kesalahan. Secara umum MA berordo q dapat dinyatakan sebagai ARIMA (0,0, q) atau MA (q). Persamaan dari dapat dinyatakan sebagai.

$$X_t = e_1 - \theta_1 e_{i-1} - \theta_2 e_{i-2} - \dots - \theta_p e_{i-p}$$

Keterangan:

θ_p : parameter *Moving Avarage*,

e_{t-p} : nilai *error* pada saat $i - q$

3. *Exponential smoothing*

Metode ini merupakan pengembangan dari *Moving Average*, namun memberikan bobot yang berbeda untuk setiap data masa lalu. Data yang paling baru diberikan bobot yang lebih besar (secara eksponensial) karena dianggap lebih relevan dengan masa depan.

4. *Auto-Regressive Integrated Moving Average* (ARIMA)

Metode Box-Jenkins ini adalah model yang sangat fleksibel dan kuat karena menggabungkan tiga komponen, *Auto-Regressive* (AR) adalah Hubungan antara nilai saat ini dengan nilai sebelumnya, *integrated* adalah proses pembedaan (*differencing*) untuk membuat data menjadi stasioner, dan *Moving Average* (MA) adalah hubungan antara nilai saat ini dengan nilai kesalahan peramalan sebelumnya.

2.2.4 Peran Peramalan dalam Keuangan

Menurut (Wahyu dkk., 2025), peramalan berfungsi sebagai alat strategis untuk meningkatkan efisiensi keuangan melalui penyediaan proyeksi kondisi keuangan masa depan yang akurat. Peran utamanya mencakup analisis keberlanjutan operasional perusahaan, penilaian kelangsungan hidup melalui kinerja dan posisi keuangan, serta menjadi acuan krusial dalam pengambilan keputusan strategis terkait investasi. Dengan menggunakan metode seperti *moving average* atau *exponential smoothing*, peramalan membantu manajemen mengantisipasi dinamika pasar, memprediksi volume penjualan agar produksi lebih tepat sasaran, dan merespons ketidakpastian lingkungan bisnis secara lebih adaptif.

2.3 Harga Emas sebagai Objek Penelitian

Menurut (Fang, 2023), emas merupakan logam mulia khusus dengan fungsi ganda sebagai uang dan komoditas yang berfungsi sebagai instrumen investasi strategis untuk menghindari risiko ekonomi. Dalam konteks penelitian *time series*, harga emas menjadi objek yang menantang karena proses pembentukan harganya yang sangat kompleks dan dipengaruhi oleh berbagai faktor global.

2.3.1 Pengertian Emas sebagai Aset

Menurut (Vita dan Wulandari, 2025), emas didefinisikan sebagai aset *safe haven*, yaitu instrumen investasi yang dipercaya mampu menjaga atau bahkan meningkatkan nilainya di tengah situasi krisis dan ketidakpastian ekonomi. Lebih dari sekadar komoditas finansial, emas dimaknai secara holistik sebagai simbol keamanan dan stabilitas hidup yang memiliki nilai simbolik serta kultural yang sangat kuat bagi investor ritel di Indonesia. Sebagai aset pelindung nilai (*hedge*), emas berfungsi menjaga kekayaan dari fluktuasi pasar sekaligus berperan sebagai "pengaman psikologis" yang membantu individu melatih kontrol diri dan kedisiplinan dalam mengelola pengeluaran keuangan pribadi. Selain itu, emas dianggap sebagai aset yang fleksibel untuk mendukung kemandirian ekonomi serta perencanaan masa depan jangka panjang, seperti dana pendidikan anak atau cadangan darurat keluarga.

2.3.2 Karakteristik Harga Emas

Menurut (Vita dan Wulandari, 2025) karakteristik harga emas ini digambarkan sebagai aset yang sangat responsif terhadap ketidakpastian global, di mana nilainya memiliki kecenderungan untuk meningkat atau tetap stabil di tengah situasi krisis seperti perang dagang, pandemi, maupun konflik geopolitik. Harga emas menunjukkan

hubungan yang berlawanan dengan aset berisiko seperti saham, sehingga sering dianggap sebagai instrumen yang lebih aman, meskipun efektivitasnya sebagai pelindung nilai (*hedge*) bersifat dinamis serta sangat bergantung pada konteks makroekonomi dan dinamika psikologis investor. Walaupun dipersepsikan stabil oleh banyak pihak, harga emas tetap memiliki karakteristik fluktuatif yang "kadang naik dan kadang turun," yang mencerminkan adanya sisi risiko dan ketidakpastian yang dapat menimbulkan tekanan emosional bagi para investor ritel.

2.3.3 Faktor yang Mempengaruhi Harga Emas

Penentuan harga emas dipengaruhi oleh mekanisme pasar global sebagai berikut:

1. Indeks Dolar AS (USD): Hubungan terbalik (korelasi negatif). Jika USD menguat, emas cenderung melemah.
2. Suku Bunga (*The Fed*): Kenaikan suku bunga meningkatkan *opportunity cost* memegang emas (karena emas tidak memberikan bunga/dividen).
3. Kondisi Geopolitik: Perang atau krisis politik meningkatkan permintaan emas sebagai *safe haven*.

2.4 Seasonal Autogressive Integrated Moving Average (SARIMA)

Seasonal Autoregressive Integrated Moving Average (SARIMA) merupakan pengembangan dari metodologi Box-Jenkins yang dirancang khusus untuk menangani data *time series* dengan karakteristik musiman. Hingga saat ini, SARIMA tetap menjadi salah satu instrumen peramalan yang paling reliabel dan banyak diimplementasikan dalam berbagai studi kasus pola musiman.

2.4.1 Model Autogressive (AR)

Autogressive merupakan bentuk dari *regresif* tetapi keduanya berbeda. *Regresif* menghubungkan variabel bebas dengan variabel terikat, sedangkan *autogressive* merupakan variabel dependen dipengaruhi oleh variabel itu sendiri karena data yang digunakan merupakan data tunggal atau variabel saat ini dipengaruhi oleh variabel masa lalu. Persamaan umum dari AR(p) dinyatakan seperti berikut.

$$X_t = \phi_1 X_{(t-1)} + \phi_2 X_{(t-2)} + \phi_3 X_{(t-3)} + \dots + \phi_p X_{(t-p)} + e_t$$

Keterangan:

- | | |
|---------------------------------|----------------------------------|
| X_t | : variabel yang diramalkan, |
| $\phi_1, \phi_2, \dots, \phi_p$ | : parameter AR ordo ke 1,2,...,p |
| X_{t-p} | : variabel pada saat $t - p$, |
| e_t | : error pada periode t |

2.4.2 Model *Moving Average* (MA)

Moving average adalah teknik peramalan deret waktu (*time series*) stasioner yang memprediksi nilai masa depan berdasarkan rata-rata kesalahan (residual) dari data masa lampau. Model ini digunakan untuk menghaluskan data, menonjolkan tren, dan menangkap guncangan mendadak. Seringkali, MA dikombinasikan dalam model *Autoregressive Integrated Moving Average* (ARIMA) untuk peramalan akurat.

2.4.3 Model *Autoregressive Moving Average* (ARMA)

Model *Autoregressive Moving Average* (ARMA) merupakan sebuah model hibrida yang mengintegrasikan dua mekanisme prediktif sekaligus masa lalu dari data itu sendiri (AR) dan masa lalu dari kesalahan prediksi (MA). Model ini dirancang untuk menangkap pola data yang lebih kompleks yang tidak bisa dijelaskan hanya oleh satu metode saja. Persamaan umum model ARMA dengan orde (p, q) dapat dinyatakan sebagai berikut:

$$Z_t = \phi_1 Z_{(t-1)} + \dots + \phi_p Z_{(t-p)} + e_t - \theta_1 e_{(t-1)} - \dots - \theta_q e_{(t-q)}$$

Keterangan:

Z_t : mewakili nilai data pada periode waktu ke- t ,

$Z_{(t-p)}$: nilai historis dari data itu sendiri hingga lag ke- p ,

e_t : nilai kesalahan (*error*) pada periode t ,

$e_{(t-q)}$: nilai kesalahan (*error*) pada periode $t - q$,

ϕ_p : parameter *autoregressive* ke- p ,

θ_q : parameter *autoregressive* ke- q .

2.4.4 Model *Autoregressive Integrated Moving Average* (ARIMA)

Model *Autoregressive Integrated Moving Average* (ARIMA) merupakan evolusi langsung dari model ARMA yang dirancang secara khusus untuk menangani data deret waktu (*time series*) yang bersifat tidak stasioner. Penambahan parameter integrasi (d) memungkinkan model menangkap tren jangka panjang atau perubahan rata-rata dalam data melalui proses pembedaan (*differencing*) sebelum penerapan pemodelan stokastik. Model ini sering dinotasikan sebagai ARIMA (p, d, q) , di mana:

$$Z_t = \phi_0 + (1 + \phi_1)Z_{(t-1)} + (\phi_2 - \phi_1)Z_{(t-2)} + \dots + (\phi_p \phi_{(p-1)})Z_{(t-p)} - \phi_p Z_{(t-p-1)} + a_t - \theta_1 a_{(t-1)} - \dots - \theta_q a_{(t-q)}$$

Keterangan:

Z_t : data pada periode t ,

$Z_{(t-p)}$: data pada periode $t - p$,

a_t : *error* pada periode t ,

- $a_{(t-q)}$: *error* pada periode $t - q$,
 ϕ_0 : konstan,
 ϕ_p : parameter *autogressive* ke- p ,
 θ_q : parameter *autogressive* ke- q .

2.4.5 Model Seasonal Autogressive Moving Average (SARMA)

Persamaan umum dari bentuk *Seasonal Autogressive Moving Average* (SARMA) periode S adalah sebagai berikut:

$$Z_t = \phi_1 Z_{(t-s)} + \phi_2 Z_{(t-2s)} + \dots + \phi_p Z_{(t-ps)} + a_t - \theta_1 a_{(t-s)} - \theta_2 a_{(t-2s)} - \dots - \theta_q a_{(t-qS)}$$

Keterangan:

- Z_t : nilai runtun waktu yang *stasioner*,
 $a_{(t-s)}, a_{(t-2s)}$: nilai kesalahan sebelumnya,
 $Z_{(t-s)}, Z_{(t-2s)}$: nilai periode sebelumnya,
 ϕ_1, ϕ_2, ϕ_p : koefisien model *autogressive* (AR),
 $\theta_1, \theta_2, \theta_q$: koefisien *moving average* (MA),
 a_t : kesalahan parameter model *moving average* (MA).

2.4.6 Model Seasonal Autogressive Integrated Moving Average (SARIMA)

Model *Seasonal Autoregressive Integrated Moving Average* (SARIMA) merupakan perluasan dari model *autogressive integrated moving Average* (ARIMA) yang dirancang khusus untuk menangani data deret waktu yang mengandung pola musiman. Suatu model ARIMA yang mengandung suatu pola musiman dapat dinotasikan dengan SARIMA $(p,d,q)(P,D,Q)^S$, berikut keterangan rumus $(P,D,Q)^S$:

- p,d,q : bagian yang tidak musiman dari model,
 $(P,D,Q)^S$: merupakan bagian musiman dari model,
 S : merupakan jumlah periode per musim.

Rumus umum dari SARIMA $(p,d,q)(P,D,Q)^S$ sebagai berikut:

$$\phi_p(B)\Phi_P(B^S)(1-B)^d(1-B^S)^D Z_t = \theta_q(B)\Theta_Q(B^S)\alpha_t$$

Dengan,

- $\phi_p(B)$: merupakan *autogressive integrated non-seasonal*,
 $\Phi_P(B^S)$: merupakan *autogressive integrated seasonal*,
 $(1-B)^d$: *differencing non-seasonal*,
 $(1-B^S)^D$: *differencing seasonal*,
 $\theta_q(B)$: *moving average (MA) non-seasonal*,
 $\Theta_Q(B^S)$: *moving average (MA) seasonal*.

Terdapat beberapa tahapan yang harus dilakukan dalam melakukan peramalan dengan metode SARIMA yaitu sebagai berikut:


1. Identifikasi Model
2. Penaksiran Parameter Model Sementara
3. Pemeriksaan Diagnostik

2.4.7 Pengertian ARIMA dan SARIMA

Autoregressive Integrated Moving Average merupakan (ARIMA) metode analisis deret waktu klasik yang dikembangkan oleh Box-Jenkins dengan mengombinasikan komponen AR, I, dan MA untuk mentransformasi data non-stasioner menjadi stasioner. Sebagai pengembangan, *Seasonal Autoregressive Integrated Moving Average* (SARIMA) hadir dengan menambahkan parameter musiman ke dalam model, sehingga sangat relevan dan adaptif untuk menangkap fluktuasi periodik dalam peramalan harga emas. Model hibrida linier ini secara matematis dinotasikan sebagai $ARIMA(p, d, q)(P, D, Q)_s$.

Keterangan:

- p : orde *Auto Regresif* (AR),
 d : derajat *differencing non-musiman*,
 q : orde *Moving Average* (MA),
 P : orde *Auto Regresif non-musiman*,
 D : *differencing musiman*,
 Q : order *Moving Average musiman*,
 s : panjang periode musim.



Gambar 2.1 Arsitektur Arima dan Sarima

2.4.8 Persamaan Umum SARIMA

Secara sistematis, model SARIMA (p,d,q)(P,D,Q)s dinyatakan melalui operator *backshift* (B) sebagai berikut:

$$\phi_p(B)\Phi_P(B^s)(1-B)^d(1-B^s)^D Y_t = \theta_q(B)\Theta_Q(B^s)\epsilon_t$$

Keterangan:

- Y_t : Nilai pengamatan (data harga emas) pada waktu ke- t
 ϵ_t : Sisaan (residual) atau *error* yang bersifat *white noise* pada waktu ke- t .
 B : *Operator backshift*, di mana $B^k Y_t = Y_{t-k}$

2.4.9 Komponen Model SARIMA

1. Autoregressive (AR): Hubungan antara pengamatan saat ini dengan nilai pada periode sebelumnya.
2. Integrated (I): Proses pembedaan (*differencing*) untuk membuat data menjadi stasioner.
3. Moving Average (MA): Hubungan antara pengamatan saat ini dengan *error* (galat) dari periode sebelumnya.
4. Seasonal: Pengulangan pola pada interval waktu yang tetap (misal: bulanan atau tahunan).

2.4.10 Kelebihan dan Keterbatasan SARIMA

Metode *Seasonal Autoregressive Integrated Moving Average* (SARIMA) merupakan salah satu algoritma statistik klasik yang paling mapan dan banyak digunakan dalam analisis data deret waktu parametrik. Namun, seperti halnya model statistik tradisional lainnya, SARIMA memiliki karakteristik linieritas yang ketat, yang membawa kombinasi keunggulan sekaligus batasan fundamental saat diterapkan pada data keuangan:

1. Kelebihan SARIMA:
Seasonal Autoregressive Integrated Moving Average (SARIMA) sangat kuat dan andal untuk memodelkan komponen linier serta pola musiman (seasonal) yang bersifat kaku dan terstruktur. Melalui kombinasi parameter autoregresif (p, P), pembedaan (differencing d, D), dan rata-rata bergerak (q, Q), SARIMA mampu menangkap tren jangka panjang sekaligus fluktuasi periodik yang berulang secara konsisten pada rentang waktu tertentu (misalnya pola harian, mingguan, atau bulanan). Jika data deret waktu didominasi oleh pergerakan linier yang stabil, SARIMA dapat memberikan hasil peramalan dengan tingkat akurasi dan interpretabilitas statistik yang sangat tinggi.
2. Keterbatasan utama model SARIMA terletak pada asumsi dasar bahwa hubungan antara data masa lalu dan data masa depan bersifat linier. Di dunia nyata, pergerakan harga komoditas aktif seperti emas (XAUUSD) bersifat sangat dinamis dan kerap mengalami gejolak pasar yang tiba-tiba (*structural breaks*), yang dipengaruhi oleh faktor eksternal seperti krisis geopolitik, perubahan kebijakan suku bunga, inflasi global, maupun sentimen pasar. Karena tidak memiliki fleksibilitas matematis untuk memproses fungsi non-linier, SARIMA gagal menangkap hubungan non-linier terstruktur tersebut. Ketidakmampuan ini menyebabkan model SARIMA menghasilkan kesalahan peramalan (*forecasting error*) yang cukup besar ketika dihadapkan pada volatilitas tinggi.

2.5 Residual dalam Peramalan

Dalam pemodelan statistika dan peramalan deret waktu, residual sering kali disalahpahami hanya sebagai "sampah" atau sisa numerik yang tidak memiliki nilai fungsional. Namun, dalam perspektif pemodelan hibrida *modern*, residual dipandang sebagai metrik krusial yang menyimpan informasi berharga yang tertinggal dari proses pemodelan linier. Ketika model linier seperti SARIMA selesai dilatih, ia hanya

menyerap pola linier dari data historis. Seluruh varians, pola fluktuasi *non-linier*, dan dinamika asimetris yang gagal ditangkap oleh SARIMA akan mengendap di dalam komponen residual ini. Oleh sebab itu, alih-alih mengabaikannya, residual dapat diekstraksi dan diperlakukan sebagai deret waktu baru yang memuat sinyal-sinyal *non-linier* penting. Melalui pendekatan ini, komponen residual dimanfaatkan sebagai basis data utama untuk melatih model kecerdasan buatan (*Machine Learning/Deep Learning*) seperti LSTM, yang bertindak sebagai mekanisme koreksi kesalahan (*error correction mechanism*) demi meningkatkan akurasi total dari sistem peramalan.

2.5.1 Pengertian Residual

Secara matematis dan teoretis, residual didefinisikan sebagai selisih secara acak antara nilai observasi yang sebenarnya terjadi di lapangan (nilai aktual) dengan nilai hasil estimasi yang dikeluarkan oleh model peramalan pada titik waktu yang sama. Dalam konteks penelitian ini, semua residual dihitung dari hasil dekomposisi linier model SARIMA. Secara formal, residual dirumuskan sebagai selisih antara nilai observasi aktual (y_t) dengan nilai prediksi dari model ($\hat{y}_t$), yang dinyatakan melalui persamaan matematika berikut:

$$e_t = y_t - \hat{y}_t$$

Keterangan:

- (e_t) : nilai residual (kesalahan peramalan) pada periode t ,
- (y_t) : data asli (nilai aktual) pada periode t ,
- ($\hat{y}_t$) : data hasil peramalan model pada periode t .

Melalui persamaan ini, nilai e_t mempresentasikan seberapa jauh melesetnya prediksi model SARIMA terhadap harga aktual emas dunia. Jika nilai e_t yang dihasilkan setelah uji statistik terbukti tidak acak (*non-white noise*), hal tersebut menjadi bukti empiris yang valid bahwa residual tersebut masih mengandung struktur informasi tersembunyi yang siap diidentifikasi dan di prediksi lebih lanjut oleh arsitektur LSTM.

2.5.2 Konsep White Noise

Dalam suatu proses $\{a_t\}$ dikatakan sebagai proses white noise jika ia merepresentasikan suatu proses acak murni. Secara sederhana, ini adalah "kebisingan" yang benar-benar acak, tanpa pola tersembunyi yang dapat diprediksi. Dalam proses ini menggunakan uji Ljung-Box persamaan sebagai berikut:

$$Q = n(n+2) \sum_{k=1}^k \frac{\rho_k^2}{n-k}$$

Dengan,

n : jumlah data,

k : nilai *lag*,


p_k : nilai fungsi autokorelasi *lag* ke- k .

2.5.3 Residual sebagai informasi Tambahan

Residual yang tidak bersifat acak (*non-white noise*) mengandung pola non-linier yang kompleks. Dalam pendekatan *hybrid*, residual ini dipandang bukan sebagai kesalahan yang harus dibuang, melainkan sebagai data deret waktu baru yang menyimpan karakteristik volatilitas atau hubungan non-linier. Dengan memodelkan residual menggunakan algoritma *Machine Learning* seperti LSTM, akurasi peramalan dapat ditingkatkan secara signifikan karena model menangkap sisa informasi yang diabaikan oleh model statistik tradisional.

2.6 Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM) adalah arsitektur *Recurrent Neural Network* (RNN) khusus yang dirancang untuk mengatasi masalah *vanishing gradient*, yaitu kondisi di mana model kehilangan kemampuan untuk mempelajari informasi dari data yang sangat lampau. LSTM sangat efektif dalam menangkap ketergantungan jangka panjang (*long-term dependencies*) pada data sekuensial harga emas yang memiliki histori panjang.




Gambar 2. 1 Pemodelan LSTM
(Sumber: Gallan, 2024)

2.6.1 Arsitektur LSTM

Kekuatan utama *Long Short-Term Memory* (LSTM) terletak pada *Cell State* (memori internal) dan mekanisme *Gate* (gerbang) untuk mengatur arus informasi:


1. Forget Gate(f_t): Memutuskan informasi mana dari masa lalu yang harus dihapus dari *cell state* menggunakan fungsi aktivasi *sigmoid*.



Gambar 2. 2 *Forget Gate*

(Sumber: Gallan, 2024)


2. Input Gate(i_t): Menentukan informasi baru mana yang akan disimpan ke dalam *cell state*.



Gambar 2. 3 *Input Gate*

(Sumber: Gallan, 2024)

3. Output Gate(o_t): Menentukan bagian mana dari *cell state* yang akan dikeluarkan sebagai *output* (prediksi) untuk langkah waktu berikutnya.



Gambar 2. 4 *Output Gate*
 (Sumber: Gallan, 2024)

2.7 Model *Hybrid* SARIMA-LSTM

Model *Hybrid* SARIMA–LSTM adalah metode peramalan (*forecasting*) time series yang menggabungkan dua pendekatan berbeda:

1. SARIMA (Statistical model) digunakan untuk menangkap pola linear, tren, dan musiman.
2. LSTM (*Deep Learning*) digunakan untuk menangkap pola non-linear dan kompleks.

2.7.1 Konsep Model *Hybrid*

Model hybrid didasarkan pada Teorema Dekomposisi, di mana data deret waktu (Y_t) diasumsikan terdiri dari komponen linier (L_t) dan komponen non-linier (N_t):

$$Y_t = L_t + N_t$$

SARIMA digunakan untuk memodelkan L_t , sementara LSTM digunakan untuk memodelkan N_t .

2.7.2 Mekanisme SARIMA-LSTM

Proses penggabungan dilakukan melalui pendekatan pemodelan residual sebagai berikut:

1. Tahap Linier: Model SARIMA dilatih pada data harga emas asli untuk menghasilkan prediksi linier ($\hat{L}_t$).
2. Ekstraksi Residual: Menghitung residual $e_t = Y_t - \hat{L}_t$.
3. Tahap Non-Linier: Residual e_t menjadi input bagi model LSTM untuk memprediksi komponen non-linier ($\hat{N}_t$).
4. Agregasi: Prediksi akhir ($\hat{Y}_t$) diperoleh dengan menjumlahkan hasil kedua model:

$$\hat{Y}_t = \hat{L}_t + \hat{N}_t$$

2.7.3 Keunggulan Model Hybrid

Model ini menjadi lebih umum ketika kedua pendekatan digabungkan. Berbeda dengan LSTM, yang menangani anomali dan fluktuasi non-linier, SARIMA menangani tren dan musiman secara matematis, sehingga menghasilkan *error* peramalan yang lebih kecil dibandingkan dengan model tunggal.

2.8 Evaluasi Model Peramalan

Evaluasi model peramalan adalah proses untuk menilai seberapa akurat dan andal hasil prediksi yang dihasilkan oleh suatu model (misalnya SARIMA, LSTM, atau *Hybrid*).

2.8.1 Mean Absolute Error (MAE)

Mean Absolute Error (MAE) adalah metrik evaluasi yang mengukur rata-rata besarnya kesalahan (selisih *absolut*) antara nilai prediksi dan nilai aktual dalam model regresi atau peramalan. MAE dihitung dengan menjumlahkan *absolut* selisih prediksi dan data riil, lalu dibagi jumlah sampel.

$$MAE = \frac{1}{n} \sum_{t=1}^n |A_t - F_t|,$$

Keterangan:

- n : ukuran *sample*,
- A_i : nilai data aktual ke- i
- F_i : nilai data per amalan ke- i

2.8.2 Root Mean Squared Error (RMSE)

Root Mean Squared Error (RMSE) adalah salah satu metrik evaluasi yang digunakan untuk mengukur tingkat akurasi prediksi model dengan menghitung akar kuadrat dari rata-rata selisih kuadrat antara nilai aktual dan nilai prediksi. Rumus dari metode sebagai berikut:

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

Keterangan:

- n : jumlah total data atau observasi,
- $t = 1$: tanda proses penjumlahan dimulai dari data pertama,
- y_t : nilai aktual pada waktu t ,
- $\hat{y}_t$: nilai prediksi pada waktu t ,
- $(y_t - \hat{y}_t)$: nilai kesalahan prediksi untuk satu data tunggal,
- $(y_t - \hat{y}_t)^2$: nilai kesalahan yang di kuadratkan

2.8.3 *Mean Squared Error (MSE)*

Mean Squared Error (MSE) merupakan metode lain untuk mengevaluai metode peramalan. Metode ini menghasilkan kesalahan-kesalahan sedanya yang kemungkinan lebih baik untuk kesalahan kecil, tetapi kadang menghasilkan perbedaan yang besar. Semakin kecil MSE yang didapat, maka semakin akurat juga peramalan yang dilakukan. Rumus dari metode ini sebagai berikut:

$$MSE = \frac{\sum_{t=1}^n (Y_t - \hat{Y}_t)^2}{n}$$

Keterangan:

- n : banyak observasi,
 Y_t : data asli pada periode t ,
 $\hat{Y}_t$: data hasil peramalan periode t .

2.8.4 *Mean Absolute Percentage Error (MAPE)*

Mengukur akurasi dalam bentuk persentase. Menurut (H. C. Chen dkk., 2013), nilai MAPE < 10% dikategorikan sebagai kemampuan peramalan yang sangat baik (*highly accurate*).

$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \times 100\% ,$$

Keterangan:

- n : banyak observasi,
 y_t : data asli pada periode t ,
 $\hat{y}_t$: data hasil peramalan periode t .

HALAMAN INI SENGAJA DIKOSONGKAN

BAB III


ANALISIS DAN PERANCANGAN

3.1 Tempat dan Waktu Penelitian

Tempat diadakannya penelitian ini adalah Kampus Institut Bisnis Dan Teknologi Indonesia yang beralamat di JL. Tukad Pakerisan 97 Denpasar Bali – Indonesia. Waktu dilaksanakannya penelitian ini adalah Januari 2026.

3.2 Teknik Pengumpulan Data

Data yang digunakan dalam penelitian ini adalah data sekunder berupa harga penutupan harian emas dunia (*Gold Spot/XAAUSD*) dalam rentang waktu 2020 hingga 2025. Data akan diperoleh dari sumber terpercaya yaitu Yahoo Finance dalam format deret waktu (*time series*).



Date	Open	High	Low	Close	Adj Close	Volume
Dec 30, 2025	4,346.40	4,403.60	4,338.00	4,370.10	4,370.10	1,837
Dec 29, 2025	4,371.50	4,379.00	4,325.10	4,325.10	4,325.10	2,044
Dec 26, 2025	4,812.00	4,856.30	4,502.00	4,529.10	4,529.10	263
Dec 24, 2025	4,500.70	4,503.40	4,468.40	4,480.60	4,480.60	500
Dec 23, 2025	4,503.30	4,503.80	4,450.40	4,482.80	4,482.80	694
Dec 22, 2025	4,371.10	4,447.60	4,371.10	4,444.60	4,444.60	449
Dec 19, 2025	4,350.10	4,361.40	4,350.10	4,361.40	4,361.40	1,066
Dec 18, 2025	4,331.00	4,348.10	4,328.20	4,339.50	4,339.50	706
Dec 17, 2025	4,308.50	4,361.40	4,308.50	4,347.50	4,347.50	2,169
Dec 16, 2025	4,270.50	4,321.40	4,270.50	4,304.50	4,304.50	1,796
Dec 15, 2025	4,308.30	4,349.20	4,292.90	4,306.70	4,306.70	854
Dec 12, 2025	4,278.40	4,355.00	4,260.00	4,300.10	4,300.10	1,531
Dec 11, 2025	4,224.00	4,286.90	4,214.30	4,285.50	4,285.50	628
Dec 10, 2025	4,209.00	4,234.50	4,183.60	4,196.40	4,196.40	692
Dec 9, 2025	4,190.70	4,219.70	4,177.70	4,206.70	4,206.70	660
Dec 8, 2025	4,205.50	4,215.80	4,175.50	4,187.20	4,187.20	318
Dec 5, 2025	4,204.10	4,265.70	4,194.60	4,212.90	4,212.90	633


Gambar 3. 1 Website Yahoo Finance (Data Hrga Emas GC=F)

Date	Price	Close GC=F	High GC=F	Low GC=F	Open GC=F	Volume GC=F
02/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	214
03/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	107
04/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	416
05/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	47
06/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	298
07/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	54
08/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	16
09/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	48
10/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	32
11/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	11
12/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	98
13/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	108
14/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	45
15/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	42
16/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	15
17/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	43
18/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	22
19/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	3
20/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	21274
21/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	62336
22/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	3995
23/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	1082
24/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	978
25/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	1305
26/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	1305
27/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	431
28/01/2020	1524.5	1,549,199,951.171,870	1,528,699,951.171,870	1,518,199,951.171,870	1,530,999,951.171,870	128

Gambar 3. 2 Data Sekunder Mentah Harga Emas file CSV

3.3 Eksplorasi Data dan Analisis Harga Emas

Analisis deskriptif dan eksplorasi data dilakukan terlebih dahulu untuk memahami karakteristik fundamental dari data deret waktu (*time series*) yang digunakan dalam penelitian ini. Data yang dianalisis merupakan data historis harga penutupan harian emas dunia dengan simbol ticker GC=F yang diperoleh melalui *library* yfinance sejak Januari 2020 hingga akhir tahun 2025. Visualisasi pergerakan harga emas tersebut disajikan pada Gambar 3.3 berikut:



Gambar 3. 3 Data Historis Harga Emas Periode 2020-2025

Berdasarkan visualisasi pada Gambar 3.3 terdapat beberapa karakteristik dan fenomena penting pada pergerakan harga emas yang melandasi pentingnya dilakukan prediksi serta pemilihan metode dalam penelitian ini.

3.3.1 Adanya Tren Kenaikan Jangka Panjang (*Long-term Upward Trend*)

Secara keseluruhan, data historis menunjukkan kecenderungan arah (*trend*) yang meningkat secara signifikan sepanjang periode pengamatan. Fluktuasi harga ini dapat dibagi menjadi dua fase pergerakan utama berdasarkan karakteristik pasarnya:

1. Fase Konsolidasi Jangka Panjang tahun 2020 – Pertengahan 2023: Pada rentang waktu 2020 hingga pertengahan 2023, harga emas bergerak fluktuatif di dalam area pembatasan harga (*trading range*) yang relatif stabil, yaitu berkisar antara 1.500 USD hingga 2.000 USD per *troy ons* (atau setara dengan kisaran harga per 31,1035 gram). Fase *sideways* yang panjang ini mencerminkan kondisi konsolidasi pasar global, di mana kekuatan permintaan dan penawaran emas dunia berada dalam titik keseimbangan yang relatif konstan tanpa adanya pembentukan tren baru yang dominan.
2. Fase Lonjakan Agresif (*Bullish Rally*) akhir 2023 – akhir 2025: Memasuki akhir tahun 2023, struktur pasar emas mengalami perubahan drastis yang ditandai dengan pecahnya batas resistansi (*breakout*) di atas 2.000 USD per *troy ons*. Harga emas mengalami akselerasi kenaikan yang sangat kuat dan eksponensial hingga menembus puncaknya di atas 4.500 USD per *troy ons* pada akhir tahun 2025. Lonjakan harga yang masif ini mengindikasikan adanya sentimen pasar global yang sangat kuat, seperti peningkatan inflasi global, ketidakpastian geopolitik, atau pelemahan mata uang utama yang mendorong fungsi emas sebagai aset pelindung nilai (*safe haven*).


Secara metodologis deret waktu, transisi dari fase konsolidasi ke fase kenaikan tajam ini mengindikasikan secara visual bahwa data tidak stasioner dalam rata-rata (*non-stationary in mean*), karena nilai rata-rata (*mean*) dari subset data di akhir periode jauh lebih tinggi dibandingkan awal periode. Karakteristik ketidakstasioneran ini memberikan landasan teoretis yang kuat bahwa data memerlukan proses transformasi stasionerisasi berupa *differencing* pada pemodelan linier SARIMA agar model tidak menghasilkan estimasi yang bias (*spurious regression*).

3.4 Alur Penelitian

Penelitian ini mengikuti kerangka kerja eksperimental yang dibagi menjadi beberapa tahapan utama sebagai berikut:

1. Identifikasi Masalah: Menganalisis keterbatasan model SARIMA dalam menangkap pola non-linier pada residual.
2. Pengumpulan Data: Mengambil data historis harga emas dunia.

3. Preprocessing Data: Pembersihan data, transformasi, dan uji stasioneritas.
4. Pemodelan SARIMA: Membangun model linier dan mengekstraksi residual.
5. Integrasi Hibrida: Melatih arsitektur LSTM untuk mempelajari pola pada residual SARIMA.
6. Evaluasi: Pengujian akurasi menggunakan metrik statistik.



Gambar 3. 4 Diagram Alur Penelitian
(Sumber: Penulis)

3.4.1 Studi Literatur

Tahapan studi literatur merupakan langkah awal yang krusial untuk membangun fondasi teoritis dan metodologis yang kuat bagi penelitian hibrida SARIMA-LSTM ini. Pada tahap ini, jurnal internasional maupun nasional, buku teks, laporan penelitian terdahulu yang relevan dengan domain peramalan deret waktu (*time series forecasting*). Fokus penelusuran literatur diarahkan pada sebagai berikut :

1. Karakter Finansial dan Pergerakan Harga Emas : memahami sifat data harga emas dunia (*Gold spot/XAUUSD*) yang fluktuatif,

memiliki volatilitas tinggi, serta rentan terhadap anomali akibat ekonomi makro.

2. Keterbatasan Pemodelan Linier Klasik (SARIMA) : mengkaji bagaimana model statistik Box-Jenkins menangani komponen tren dan musiman, sekaligus mengidentifikasi celah di mana SARIMA kerap kali menyisakan pola *non*-linier terstruktur pada residualnya.

3.4.2 Analisis Data

Analisis data dilakukan untuk memeriksa dan memahami propoerti statistik dari data mentah sebelum masuk ke dalam data tahap perancangan model hibrida. Data yang menjadi objek dalam penelitian ini adalah data sekunder berupa harga penutupan harian emas dunia (*Gold Spot/XAUUSD*) dalam rentang waktu periode 2020 hingga 2025. Proses analisis ini meliputi beberapa pemeriksaan mendalam:

1. Analisis Tren dan Pola Runtun Waktu: mengamati plot data historis secara visual untuk mendeteksi keberadaan tren naik/turun serta fluktuasi periodik (*seasonality*) yang melekat pada pergerakan harga emas akibat siklus pasar finansial.
2. Uji Asumsi Stasioneritas: menguji kondisi stasioneritas data historis, baik terhadap rata-rata (*mean*) maupun varians. Secara formal, pengujian ini dilakukan menggunakan uji statistik *Augmented Dickey-Fuller* (ADF). Jika data asli terbukti tidak stasioner (memiliki nilai $p - value > 0,05$ atau berada di atas nilai kritis), maka data tersebut dipastikan membutuhkan transformasi pembedaan (*differencing*).
3. Analisis Autokorelasi Awal (ACF dan PACF): memeriksa grafik *Autocorrelation Function* untuk menangkap indikasi kekuatan ketergantungan linier antar-periode waktu, yang nantinya akan menjadi basis subjektif dalam menentukan estimasi awal ordo non-musiman p, d, q dan musiman $(P, D, Q)s$ pada model SARIMA.

3.4.3 Persiapan Data

Tahapan persiapan data atau *preprocessing* bertujuan untuk mentransformasikan data mentah (*raw data*) harga emas ke dalam format yang bersih, stabil, dan siap diproses secara optimal oleh algoritma SARIMA maupun arsitektur *deep learning* LSTM. Langkah-langkah sistematis yang dilakukan pada tahap ini meliputi:


1. Pembersihan data (*Data Cleaning*): memeriksa struktur data untuk memastikan tidak ada nilai yang hilang (*missing value*) atau baris yang kosong akibat hari libur pasar finansial (*weekend/market*

closure). Jika ditemukan, dilakukan penanganan menggunakan metode interpolasi linier agar kontinuitas runtun waktu tetap terjaga.

2. Transformasi Stasioneritas (*Differencing*): berdasarkan hasil analisis pada data uji ADF, dilakukan proses perbedaan (*differencing*) pada tingkat $d(\text{non} - \text{musiman})$ atau $D(\text{musiman})$ hingga data harga emas mencapai kondisi stasioner. Data yang telah stasioner inilah yang menjadi input utama bagi pemodelan linier SARIMA.
3. Normalisasi Data (*Data Acaling*): khusus untuk kebutuhan pemodelan residual oleh lstm pada tahap berikutnya, data runtun waktu residual perlu dinormalisasi menggunakan metode *Min-Max Scaling* ke dalam rentang nilai 0 hingga 1 atau -1. Langkah ini wajib dilakukan untuk mempercepat proses konvergensi dan mencegah terjadinya ledakan bobot (*gradient explosion*) saat pelatihan jaringan saraf LSTM.
4. Pembagian Data (*Data Splitting*): membagi dataset runtun waktu secara kronologis (tanpa pengacakan/*suffle*) menjadi komponen *Data Training* (untuk melatih estimasi parameter SARIMA dan bobot jaringan LSTM) serta *Data Training* (untuk melatih estimasi parameter SARIMA dan bobot jaringan LSTM) serta *Data Testing* atau *Validation* (untuk mengevaluasi peforma prediksi kesalahan dan mengukur tingkat akurasi final hibrida melalui metrik RMSE, MAE, dan MAPE).

3.5 Prosedur Pemodelan SARIMA-LSTM


Pendekatan hibrida dalam penelitian ini didasarkan pada asumsi teoretis dekomposisi runtun waktu, yang menyatakan bahwa pergerakan harga emas merupakan kombinasi kompleks dari komponen linier dan komponen non-linier. Model tunggal linear seperti SARIMA sering kali menyisakan bias fluktuasi karena tidak mampu menangkap dinamika pasar yang tidak stabil. Oleh karena itu, prosedur pemodelan dirancang secara sekuensial (berurutan) di mana model SARIMA bertindak sebagai pemodel linier utama, kemudian dilanjutkan dengan jaringan LSTM yang bertindak sebagai pemodel residual untuk mengekstrak dan memprediksi pola error (non-linier) yang tertinggal.



Gambar 3. 5 Alur pemodelan SARIMA-LSTM

3.5.1 Penerapan Metode Sliding Window

Dalam penelitian ini, data historis harga emas dunia (*Gold Futures*) dengan simbol GC=F diunduh langsung melalui *library yfinance* di lingkungan *Google Colab* untuk periode waktu 1 Januari 2020 hingga 31 Desember 2025. Sebelum melatih arsitektur *Long Short-Term Memory* (LSTM) untuk mengoreksi kesalahan peramalan, data residual hasil pemodelan SARIMA harus ditransformasikan terlebih dahulu menggunakan metode *sliding window*. Karena data dari Yahoo Finance merupakan representasi transaksi harian bursa (tidak termasuk akhir pekan dan hari libur pasar), deret waktu residual yang dihasilkan berbentuk satu dimensi linier (*univariate*). Format tunggal ini tidak dapat langsung dibaca oleh *input layer* LSTM yang mensyaratkan dimensi matriks 3D yaitu *samples*, *time steps*, *features*. Oleh karena itu, *sliding window* diterapkan untuk memotong dan menggeser rangkaian data sekuensial tersebut menjadi pasangan variabel *input* (X) dan variabel *target* (Y).



Gambar 3. 6 Visualisasi Sliding Window

Berdasarkan Gambar 3.6 , mekanisme transformasi deret waktu tunggal (*univariate*) menjadi struktur data yang siap dilatih pada jaringan saraf LSTM dapat dijelaskan sebagai berikut:

1. Representasi Data Awal (Deret Residual):
Bagian paling atas menunjukkan deret residual tunggal (e_t) yang disusun secara kronologis berdasarkan urutan tanggal transaksi dari Yahoo Finance, mulai dari e_1, e_2, e_3 hingga seterusnya.
2. Langkah 1 (Jendela Pertama):
Dengan asumsi ukuran jendela masa lalu (*time steps*) bernilai 3, sistem membentuk blok jendela pertama yang mencakup data $[e_1, e_2, e_3]$. Blok ini bertindak sebagai *Input (X)*. Informasi masa lalu di dalam input tersebut dipetakan secara terstruktur untuk melakukan prediksi (koreksi kesalahan) terhadap satu nilai di masa depan, yaitu e_4 , yang bertindak sebagai *Target (Y)*.
3. Langkah 2 (Pergeseran Jendela):
Pada tahapan berikutnya, jendela bergeser maju tepat 1 langkah (*stride* = 1) tanpa mengubah ukuran jendela (*time steps* = 3). Kini, data input (*X*) yang diambil beralih menjadi $[e_2, e_3, e_4]$ dan digunakan untuk memproyeksikan target (*Y*) berikutnya, yaitu e_5 . Proses pergeseran berurutan ini terus diulangi sepanjang 1.511

baris data historis secara kronologis tanpa adanya pengacakan posisi data (*no shuffling*).

4. Format Akhir untuk *Input Layer* LSTM:

Pada bagian dasar gambar, kumpulan pasangan matriks 2D (X dan Y) hasil bentuk jendela geser tersebut di-*reshape* ke dalam struktur matriks 3 dimensi dengan format *samples, time steps, features*. Format 3D inilah yang menjadi syarat mutlak agar arsitektur LSTM di Google Colab dapat mengenali dependensi temporal dan memproses pola volatilitas harga emas secara mendalam.

3.5.2 Pemodelan Linier (SARIMA)

Pemodelan linier dalam penelitian ini menggunakan metode *Seasonal Autoregressive Integrated Moving Average* (SARIMA). Penentuan parameter model $(p, d, q)(P, D, Q)_s$ dilakukan dengan mengikuti metodologi sistematis Box-Jenkins. Tahapan pemodelan linier ini dibagi menjadi tiga langkah utama mendalam sebagai berikut:

1. Identifikasi Model (*Identification*)

Tahap awal ditujukan untuk menganalisis karakteristik data historis harga emas dan memastikan pemenuhan asumsi stasioneritas data, baik terhadap rata-rata (mean) maupun varians. Langkah-langkah pada tahap identifikasi meliputi:

- 1) Uji Stasioneritas Formal : menggunakan uji *Augmented Dickey-Fuller* (ADF). Jika nilai $p - value > 0,05$, data dinyatakan tidak stasioner dan harus melalui proses pembedahan (*differencing*) pada tingkat d (non-musiman) atau D (musiman) hingga data mencapai kondisi stasioner ($p - value < 0,05$)
- 2) Analisis Plot Korelasi : memeriksa grafik *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF) dari data yang telah stasioner. Pola grafik ini digunakan sebagai basis subjektif untuk mengidentifikasi nilai *order autogresif* non-musiman (p), *moving average* non-musiman (q), *autogresif* musiman (P), dan *moving average musiman* (Q).

2. Estimasi Parameter (*Estimation*)

Setelah beberapa kandidat kombinasi parameter model SARIMA teridentifikasi melalui plot ACF dan PACF, dilakukan proses estimasi bobot parameter menggunakan pendekatan kemungkinan


maksimum (Maximum Likelihood Estimation). Untuk menentukan satu model linier terbaik di antara berbagai kandidat yang ada, digunakan metrik pengujian Akaike Information Criterion (AIC). Formula AIC didefinisikan sebagai berikut:

$$AIC = 2k - 2 \ln(L) ,$$

Di mana k merupakan jumlah parameter dalam model dan L adalah nilai fungsi *likelihood*. Model *Seasonal Autoregressive Integrated Moving Average* (SARIMA) yang dipilih sebagai representasi linier terbaik adalah model yang menghasilkan nilai *AIC* terkecil, karena mampu memberikan keseimbangan optimal antara akurasi model (*godness of fit*) dan kesederhanaan arsitektur (*parsimony*).

3. Pemeriksaan Diagnostik (*Diagnostic Checking*): Tahap akhir dari prosedur Box-Jenkins adalah menguji kelayakan model yang telah diestimasi melalui analisis residual. Pengujian dilakukan secara statistik menggunakan Uji Ljung-Box untuk memeriksa keberadaan autokorelasi pada residual.

- 1) Jika hasil uji Ljung-Box menunjukkan bahwa residual bersifat *white noise* (tidak ada auto korelasi, $p - value > 0,05$), berarti model *Seasonal Autoregressive Integrated Moving Average* (SARIMA) telah menangkap seluruh informasi linier dengan sempurna.
- 2) Jika residual terbukti tidak bersifat *white noise* (*non-white noise*, $p - value < 0,05$), hal ini mengonfirmasi secara kuat bahwa masih terdapat struktur pola *non-linier* tersembunyi di dalam residual yang tidak mampu dimodelkan oleh SARIMA. Fenomena *non-white noise* inilah yang melandasi urgensi integritas model *Long Short-Term Memory* (LSTM) pada tahap berikutnya.



Gambar 3. 7 Model SARIMA

Tabel 3. 1 Seleksi Model SARIMA

Model SARIMA	AIC	BIC	Status
(1,1,1)(1,1,1,12)	-	-	Kandidat
(1,1,2)(1,1,1,12)	-	-	Kandidat
(2,1,1)(1,1,1,12)	-	-	Kandidat
Model Terbaik	-	-	Dipilih

3.5.3 Pemodelan Residual (LSTM)

Metode pemodelan residual digunakan untuk mengidentifikasi dan memprediksi pola-pola non-linier serta struktur fluktuasi kompleks yang tidak dapat ditangkap oleh model linier SARIMA. Metode ini menggunakan jaringan memori jangka panjang jangka pendek (LSTM) untuk mengoptimalkan informasi *error* (*non-white noise*).

1. Ekstraksi Nilai Residual Hasil Pemodelan SARIMA

Proses dimulai dengan mengambil nilai residual (e_t) yang dihasilkan dari tahapan pemodelan SARIMA pada data historis harga emas. Nilai residual ini diperoleh dari selisih antara data aktual harga emas (Y_t) dengan nilai prediksi linier yang diestimasi oleh model SARIMA ($\hat{L}_t$), yang secara matematis dirumuskan sebagai berikut:

$$e_t = Y_t - \hat{L}_t$$

Data residual (e_t) inilah yang kemudian di transformasikan dan digunakan sebagai urutan data deret waktu (*time series*) baru yang menjadi masukan (*input*) utama bagi arsitektur LSTM untuk memprediksi komponen non-linier (N_t).

2. Optimasi Hyper-parameter Menggunakan Optuna Tuning

Untuk menghindari subjektivitas pencarian parameter secara manual (*trial and error*) yang tidak efisien, penelitian ini menerapkan *automated hyper-parameter* secara heuristik dan efisien menggunakan algoritma *Tree-structured Parzen Estimator* (TPE). Komponen *hyper-parameter* model LSTM yang ditentukan dan di optimasi dalam proses *tuning* ini meliputi:

- 1) *Hidden Units*: Menentukan jumlah *neuron* pada setiap lapisan tersembunyi LSTM untuk mengatur kapasitas model dalam mempresentasikan kompleksitas data residual.
- 2) *Layer*: Menentukan kedalaman struktur jaringan (jumlah lapisan LSTM yang ditumpuk/*stacked*) untuk menangkap fitur-fitur abstrak pada tingkat yang lebih dalam.
- 3) *Dropout*: Mengatur persentase pemutusan koneksi *neuron* secara acak selama proses pelatihan guna memitigasi risiko terjadinya model mempelajari data secara berlebihan (*overfitting*) pada data latih.
- 4) *Learning Rate*: Menentukan ukuran langkah (*step size*) algoritma optimasi (misalnya Adam *Optimizer*) dalam memperbarui bobot jaringan pada setiap integrasi pengujian.

- 5) *Time Steps/Window Size*: Menentukan panjang runtun waktu atau jumlah periode masa lalu (jendela observasi) yang digunakan sebagai basis historis untuk memprediksi nilai residual satu periode ke depan.
3. Penentuan Parameter Terbaik Berdasarkan Validasi MSE
Selama proses pencarian oleh *Optuna*, setiap kombinasi *hyper*-parameter yang terbentuk akan dilatih pada data training residual dan dievaluasi menggunakan data validasi. *Optuna* dikonfigurasi dengan fungsi objektif (*objective function*) untuk meminimalkan nilai kesalahan kuadrat rata-rata. Penentuan arsitektur dan parameter terbaik model LSTM secara ketat diputuskan berdasarkan nilai *Mean Squared Error* (MSE) terkecil pada data validasi, dengan rumus:

$$MSE = \frac{1}{n} \sum_{t=1}^n (Y_t - \hat{Y}_t)^2$$


Keterangan:

n : banyak observasi,

Y_t : data asli residual pada periode t ,

$\hat{Y}_t$: data hasil peramalan residual periode t .

Kombinasi *hyper*-parameter yang menghasilkan *Mean Squared Error* (MSE) paling minimal pada tahapan ini akan dipilih sebagai arsitektur *Long Short-Term Memory* (LSTM) final untuk memprediksi nilai kesalahan (*error*) peramalan pada periode berikutnya.



Gambar 3. 8 Model Residual LSTM

Tabel 3. 2 Hasil Optimasi Hyperparameter LSTM

Trial	Hidden Units	Layers	Dropuot	Learning Rate	Time Step	Validation MSE
1	-	-	-	-	-	-
2	-	-	-	-	-	-
3	-	-	-	-	-	-
Best Trial	-	-	-	-	-	-

Tabel 3. 3 Arsitektur LSTM

Parameter	Nilai Terbaik
Hidden Units	-
Jumlah Layer	-
Dropout	-
Learning Rate	-
Time Steps	-
Optimizer	Adam
Epoch	-
Batch Size	-

3.6 Perhitungan Manual Model SARIMA-LSTM

Model hybrid SARIMA-LSTM menggabungkan keunggulan metode statistik linear *Seasonal Autoregressive Integrated Moving Average* (SARIMA) untuk menangkap pola tren dan musiman, dengan metode *Deep Learning* non-linear *Long Short-Term Memory* (LSTM) untuk memodelkan residu atau error yang tidak dapat dijelaskan oleh model SARIMA. Secara matematis, data deret waktu aktual (Y_t) didekomposisi menjadi dua komponen:

$$Y_t = L_t + N_t$$

Di mana L_t adalah komponen linear yang diprediksi oleh SARIMA, dan N_t adalah komponen non-linear (residu) yang diprediksi oleh LSTM. Langkah-langkah perhitungan manual dilakukan melalui dua tahapan besar berikut:

1. Pada tahap pertama, di mana data mentah historis terlebih dahulu distasionerkan melalui operasi *differencing* sebelum dimasukkan ke dalam persamaan matematika *Autoregressive* (AR) guna menghasilkan proyeksi tren linear (L_t). Selisih atau *error* antara nilai aktual lapangan dengan hasil kalkulasi SARIMA kemudian diisolasi menjadi deret residu (e_t).
2. Residu yang di hasilkan oleh tahap pertama inilah yang menjadi fondasi utama pada tahap ke dua, di mana deret tersebut diumpankan ke dalam sel jaringan LSTM untuk diproses melalui mekanisme *Forget Gate*, *Input Gate*, dan *Output Gate* berbasis fungsi aktivasi non-linear guna mengekstrak pola acak yang tersembunyi (N_t).

3. Akhirnya, pada tahap ke tiga, kedua matriks keluaran tersebut diintegrasikan kembali melalui penjumlahan aljabar sederhana untuk menghasilkan prediksi final yang memiliki tingkat akurasi dan presisi lebih tinggi dibandingkan model tunggal.

3.6.1 Tahap I Perhitungan Komponen Linear dengan Model SARIMA

Model SARIMA dinotasikan dengan $(p, d, q) \times (P, D, Q)_S$. Sebagai ilustrasi konkret berbasis data historis harga emas harian awal tahun 2020, diambil sampel 5 data aktual berikut (dibulatkan untuk kemudahan visualisasi perhitungan):

- 1) Y_1 (02/01/2020) = 1524.50
- 2) Y_2 (03/01/2020) = 1549.20
- 3) Y_3 (06/01/2020) = 1566.20
- 4) Y_4 (07/01/2020) = 1571.80
- 5) Y_5 (08/01/2020) = 1557.40

Misalkan berdasarkan analisis *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF), model SARIMA yang terpilih adalah SARIMA (1,1,0)(0,0,0)₀ atau setara dengan ARIMA (1,1,0) tanpa komponen musiman untuk data harian berjarak pendek.

1. Proses differencing ($d = 1$):
Transformasi stasioneritas data dilakukan dengan pengurangan:

$$\Delta Y_t = Y_t - Y_{t-1}$$

Penjelasan Rumus:

Operasi *differencing* pada langkah ini bertujuan untuk menghilangkan unsur tren non-stasioner pada data harga emas harian agar nilai rata-rata dan variansinya konisten sepanjang waktu. Melalui rumus pengurangan nilai aktual saat ini (Y_t) dengan nilai aktual satu periode sebelumnya (Y_{t-1}), data mentah diubah menjadi deret volatilitas selisih harian (ΔY_t). Pengondisian stasioneritas ini merupakan syarat mutlak agar estimasi parameter pada persamaan statistik AR tidak menghasilkan kesimpulan bias (*spurious regression*).

- 1) $\Delta Y_2 = 1549.20 - 1524.50 = 24.70$
- 2) $\Delta Y_3 = 1566.20 - 1549.20 = 17.00$
- 3) $\Delta Y_4 = 1571.80 - 1566.20 = 5.60$
- 4) $\Delta Y_5 = 1557.40 - 1571.80 = -14.40$

2. Persamaan Autoregressive Arde 1 ($p = 1$):
Rumus prediksi data stasioner sebagai berikut:

$$\Delta \hat{Y}_t = \phi_1 \cdot \Delta Y_{t-1}$$

Penjelasan Rumus:

Persamaan *Autoregressive* orde 1 (AR(1)) memodelkan hubungan linear dependen antara fluktuasi data pada waktu sekarang dengan fluktuasi data satu periode sebelumnya. Konstanta ϕ_1 bertindak sebagai koefisien bobot pengaruh historis yang nilainya didapatkan dari proses optimasi data latih. Langkah komputasi ini mengalikan koefisien ϕ_1 dengan nilai stasioner aktual hari sebelumnya (ΔY_{t-1}) untuk memperkirakan laju perubahan harga stasioner untuk target hari ini ($\Delta \hat{Y}_t$). (Diasumsikan nilai koefisien AR (ϕ_1) dari hasil estimasi adalah 0.45)

$$\Delta \hat{Y}_5 = 0.45 \cdot \Delta Y_4 = 0.45 \cdot 5.60 = 2.52$$

3. Pengembalian Nilai Prediksi Linear (L_t):

$$\hat{Y}_{SARIMA,5} = L_5 = Y_4 + \Delta \hat{Y}_5$$

Penjelasan Rumus:

Langkah integrasi balik (*de-differencing*) ini mutlak diperlukan untuk mengembalikan skala data hasil prediksi stasioner AR(1) kembali ke dalam satuan harga aslinya (USD/Troy Ounce). Proses komputasi dilakukan dengan menjumlahkan nilai harga emas aktual dari hari sebelumnya (Y_{t-1} atau Y_4) dengan proyeksi perubahan harga stasioner hasil model AR ($\Delta \hat{Y}_5$). Hasil akhir dari perhitungan ini menjadi output resmi komponen linear (L_t) dari pemodelan SARIMA.

$$\hat{Y}_{SARIMA,5} = L_5 = 1571.80 + 2.52 = 1574.32$$

4. Hitung Residu/Error (e_t):

$$e_5 = Y_5 - L_5$$

Penjelasan Rumus:

Rumus residu ini berfungsi untuk mengekstrak dan mengisolasi komponen-komponen non-linear serta variansi acak yang tidak mampu dipecahkan oleh keterbatasan asumsi linearitas pada model SARIMA. Dengan mengurangi nilai riil harga emas lapangan (Y_5) terhadap proyeksi linear SARIMA (L_5), didapatkan nilai sisaan error (e_5). Matriks deret residu (e_t) ini yang kemudian diposisikan ulang sebagai variabel *input* atau fitur utama bagi arsitektur *Deep Learning* LSTM pada tahap berikutnya.

$$e_5 = 1557.40 - 1574.32 = -16.92$$

3.6.2 Tahap II Perhitungan Komponen Non-Linear dengan LSTM

Nilai residu (e_t) dimasukkan ke dalam arsitektur LSTM dengan *time step* = 3 (menggunakan $e_{t-3}, e_{t-2}, e_{t-1}$ untuk memprediksi e_t). Diasumsikan urutan residu yang terbentuk sebelumnya adalah $e_2 = -2.1, e_3 = 1.4, e_4 = 3.5$. (Parameter bobot W , U , dan bias b diinisialisasi secara formal, fitur *input* $x_t = e_4 = 3.5$, $h_{t-1} = 0.2$, dan $C_{t-1} = 0.5$)

1. Perhitungan Forget Gate (f_t):

$$f_t = \sigma(W_f x_t + U_f h_{t-1} + b_f)$$

Penjelasan Rumus:

Forget gate (f_t) bertanggung jawab untuk menyaring informasi atau pola residu masa lalu dari *cell state* sebelumnya yang dianggap tidak lagi relevan untuk dipertahankan dalam memori jangka panjang jaringan. Operasi matematika di dalamnya mengombinasikan perkalian dot matriks antara bobot gerbang dengan input residu saat ini (x_t), ditambah bobot memori tersembunyi sebelumnya (h_{t-1}), serta bias (b_f), yang kemudian dinormalisasi menggunakan fungsi aktivasi sigmoid (σ). Output bernilai antara 0 hingga 1 ini menentukan persentase memori lama yang akan diteruskan ke perhitungan berikutnya.

$$f_t = \sigma(0.1(3.5) + 0.05(0.2) + 0.1) = \sigma(0.46) = \frac{1}{1+e^{-0.46}} = 0.613$$

2. Perhitungan Input Gate (i_t) dan Candidate State ($\tilde{C}_t$):

$$i_t = \sigma(W_i x_t + U_i h_{t-1} + b_i) \quad \text{dan} \quad \tilde{C}_t = \tanh(W_c x_t + U_c h_{t-1} + b_c)$$

Penjelasan Rumus:

Kombinasi kedua rumus ini berfungsi untuk menyeleksi dan mempersiapkan informasi non-linear baru yang akan masuk ke dalam memori internal jangka panjang. *Input gate* (i_t) menggunakan aktivasi sigmoid untuk memutuskan seberapa besar intensitas data baru yang layak diserap, sedangkan *Candidate State* ($\tilde{C}_t$) menerapkan fungsi tangen hiperbolik ($\tanh$) untuk menciptakan kandidat nilai memori baru berskala -1 hingga 1. Perkalian kedua komponen ini memastikan hanya pola residu non-linear yang valid dan signifikan yang akan dicatat oleh sistem. (Dianggap hasil kalkulasi: $i_t = 0.580$ dan $\tilde{C}_t = 0.647$)

3. Pembaruan Cell State (C_t):

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t$$

Penjelasan Rumus:

Rumus *cell state* (C_t) merupakan inti dari kapabilitas memori jangka panjang LSTM, di mana pembaruan informasi internal dilakukan secara berjalan (*streaming update*). Secara matematis, memori sel lama (C_{t-1}) dikalikan dengan faktor pelemahan *forget gate* (f_t), lalu diakumulasikan secara linear dengan informasi segar hasil seleksi *input gate* ($i_t \cdot \tilde{C}_t$). Hasil penjumlahan skalar ini merepresentasikan basis data pengetahuan internal terkini yang bebas dari masalah hilangnya gradien (*vanishing gradient*).

$$C_t = (0.613 \cdot 0.5) + (0.580 \cdot 0.647) = 0.3065 + 0.3753 = 0.6818$$

4. Output Gate (o_t) dan Hidden State (h_t atau N_t):

$$o_t = \sigma(W_o x_t + U_o h_{t-1} + b_o) \quad \text{dan} \quad h_t = o_t \cdot \tanh(C_t)$$

Penjelasan Rumus:

Langkah penutup sel LSTM ini bertujuan menghasilkan keputusan nilai keluaran prediksi residu final (h_t atau komponen N_t). Pertama, *Output gate* (o_t) mengevaluasi bagian sel mana yang akan diekspos keluar berdasarkan kondisi input terkini, kemudian nilai *cell state* (C_t) dinormalisasi kembali menggunakan fungsi tanh sebelum dikalikan dengan gerbang output tersebut. Nilai h_t yang tercipta merupakan perwujudan proyeksi koreksi non-linear atas penyimpangan model statistik SARIMA sebelumnya. (Dianggap hasil kalkulasi gerbang output: $o_t = 0.620$)

$$h_t = N_5 = 0.620 \cdot \tanh(0.6818) = 0.620 \cdot 0.5926 = 0.3674$$

3.6.3 Tahap III Integrasi Prediksi Akhir Hybrid

$$\hat{Y}_{Hybrid,t} = L_t + N_t$$

Penjelasan Rumus:

Rumus integrasi akhir ini merekonstruksi kembali sinergi utuh dari kerangka pemodelan hybrid dengan cara menjumlahkan proyeksi tren makro linear (L_t) dari subsistem SARIMA dengan proyeksi mikro non-linear (N_t) dari subsistem LSTM. Melalui skema penggabungan aditif ini, kelemahan inherent dari masing-masing metode tunggal dapat saling mereduksi, menghasilkan kurva prediksi akhir $\hat{Y}_{Hybrid}$ yang merekatkan kembali struktur linearitas global dengan fluktuasi residu lokal demi mencapai tingkat presisi prediksi harga emas yang optimal.

$$\hat{Y}_{Hybrid,5} = L_5 + N_5 = 1574.32 + 0.37 = 1574.69$$

3.7 Tahap Pengujian dan Evaluasi

Tahap pengujian dilakukan untuk mengukur, memvalidasi dan membuktikan signifikansi kontribusi performa dari model hibrida yang diusulkan. Evaluasi dilakukan secara kuantitatif untuk melihat sejauh mana arsitektur *Long Short-Term Memory* (LSTM) dapat membantu meningkatkan akurasi peramalan dengan mengoreksi sisa kesalahan (*residual*) dari model linier. Untuk membuktikan efektifitas dari integrasi metode tersebut, penelitian ini menguji dan membandingkan hasil dari dua arsitektur pemodelan berikut:

1. Model SARIMA Klasik (*Baseline*): Pemodelan statistik linier yang diterapkan langsung pada data historis harga emas dunia. Model ini berfungsi sebagai acuan dasar (*baseline*) untuk memetakan batas kemampuan metode linier sekaligus menghasilkan data *residual* (nilai kesalahan) yang akan diproses pada tahap berikutnya.
2. Model Hibrida Trintegrasi (SARIMA-LSTM): Arsitektur integrasi utama yang diusulkan, di mana nilai peramalan akhir harga emas diperoleh secara langsung dari penjumlahan hasil prediksi linier (SARIMA) dan hasil prediksi komponen non-linier pada *residual* yang diproses oleh LSTM (dengan optimasi *hyperparameter* via Optuna).

Selanjutnya, performa akurasi dari kedua arsitektur di atas akan dievaluasi dan diuji secara ketat menggunakan tiga metrik standar statistik berbasis nilai kesalahan (*error metric*) sebagai berikut:

- 1) *Mean Absolut Error* (MAE): metrik yang digunakan untuk menghitung rata-rata nilai absolut dari kesalahan prediksi, memberikan gambaran umum mengenai besaran rata-rata penyimpangan model tanpa memperhatikan arah kesalahannya (positif atau negatif)
- 2) *Mean Squared Error* (MSE): metrik yang mengukur rata-rata kuadrat dari kesalahan prediksi. Karena melakukan pengkuadratan pada setiap nilai *error*, metrik ini memberikan penalti yang lebih besar terhadap kesalahan prediksi yang bernilai besar (*outlaners*).
- 3) *Mean Absolut Percentage Error* (MAPE): metrik yang mengukur persentase rata-rata penyimpangan mutlak antara nilai aktual dan hasil peramalan. Metrik ini sangat berguna untuk mengetahui persentase akurasi relatif terhadap skala data asli harga emas.

Tabel 3. 4 Pengujian Hidden Units LSTM

Hidden Units	Model LSTM	RMSE	MSE	MAE
16	LSTM-16	-	-	-
32	LSTM-32	-	-	-
64	LSTM-64	-	-	-
128	LSTM-128	-	-	-
256	LSTM-256	-	-	-

Tabel 3. 5 Kinerja Model

Model	RMSE	MSE	MAE	MAPE
SARIMA	-	-	-	-
SARIMA-LSTM	-	-	-	-

DAFTAR PUSTAKA

- Abbasimehr, H., Paki, R., dkk. 2022. "A novel approach based on combining deep learning models with statistical methods for COVID-19 time series forecasting". **Neural Computing and Applications**, 34(4). <https://doi.org/10.1007/s00521-021-06548-9>.
- Abdulkadir, R. A., Hasan, M. K., dkk. 2023. "Novel residual hybrid machine learning for solar activity prediction in smart cities". **Earth Science Informatics**, 16(4). <https://doi.org/10.1007/s12145-023-01130-4>.
- Agaal, A., Farkash, H. M., dkk. 2025. "Towards Efficient Electricity Management in Benghazi: Forecasting Demand and Load Shedding with ARIMA Models". **Solar Energy and Sustainable Development**, 14(FICTS-2024). <https://doi.org/10.51646/jsesd.v14iFICTS-2024.446>.
- Arumugam, V., dan Natarajan, V. 2023. "Time Series Modeling and Forecasting Using Autoregressive Integrated Moving Average and Seasonal Autoregressive Integrated Moving Average Models". **Instrumentation Mesure Metrologie**, 22(4). <https://doi.org/10.18280/i2m.220404>.
- Atmanegara, E. 2022. "Peramalan Ekspor Karet Provinsi Jambi dengan Model Seasonal ARIMA". **Jurnal Ilmiah Ilmu Terapan Universitas Jambi**, 6(2). <https://doi.org/10.22437/jiituj.v6i2.22964>.
- Chen, H. C., Chen, W. J., dkk. 2013. "Estimation of chromaticity coordinates for LEDs array by modulation of red or yellow LEDs with artificial neural network". **Proceedings - 2013 9th International Conference on Intelligent Information Hiding and Multimedia Signal Processing, IIH-MSP 2013**, (1), 88–91. <https://doi.org/10.1109/IIH-MSP.2013.31>.
- Chen, H., Lu, T., dkk. 2023. "An Improved VMD–EEMD–LSTM Time Series Hybrid Prediction Model for Sea Surface Height Derived from Satellite Altimetry Data". **Journal of Marine Science and Engineering**, 11(12). <https://doi.org/10.3390/jmse11122386>.
- Fang, W. 2023. "Gold Price Forecast by Different Models", 36, 498–506.

- Heizer, Jay Render, B., dan Munson, Ummah, C. 2020. **Operations Management: Sustainability and Supply Chain Management. Sustainability (Switzerland)**, 11.
- Hendrawan, A., Vydia, V., dkk. 2021. "PREDIKSI PANDEMI COVID 19 KOTA SEMARANG MENGGUNAKAN PENDEKATAN NEURAL NETWORK". **Jurnal Riptek**, 15(1).
<https://doi.org/10.35475/ripteck.v15i1.113>.
- Kashif, K., dan Ślepaczuk, R. 2025. "LSTM-ARIMA as a hybrid approach in algorithmic investment strategies". **Knowledge-Based Systems**, 320(May), 113563.
<https://doi.org/10.1016/j.knosys.2025.113563>.
- Kontopoulou, V. I., Panagopoulos, A. D., dkk. 2023. "A Review of ARIMA vs. Machine Learning Approaches for Time Series Forecasting in Data Driven Networks". **Future Internet**, 15(8), 1–31. <https://doi.org/10.3390/fi15080255>.
- Lee, S., Brown, M., dkk. 2024. "Comparative Analysis of LSTM and Traditional Time Series Models on Oil Price Data". **Time Series Modelling**.
- Li, G., dan Yang, N. 2023. "A Hybrid SARIMA-LSTM Model for Air Temperature Forecasting". **Advanced Theory and Simulations**, 6(2). <https://doi.org/10.1002/adts.202200502>.
- Liang, L., Liu, B., dkk. 2024. "Forecasting corporate financial performance with deep learning and interpretable ALE method: Evidence from China". **Journal of Forecasting**, 43(7).
<https://doi.org/10.1002/for.3138>.
- Lubis, F. R., dan Syahputra, E. R. 2022. "Peramalan Deret Waktu untuk Bisnis : Pendekatan algoritma LGBM Regressor". **Data Sciences Indonesia (DSI)**, 1(2). <https://doi.org/10.47709/dsi.v1i2.1347>.
- Medugu, P. M., Mutah, Y., dkk. 2025. "Evaluating the Forecasting Performance of Time Series Approaches on Measles Data in Adamawa State". **International Journal of Innovative Science and Research Technology**.
<https://doi.org/10.38124/ijisrt/25aug554>.
- Gallan, V. 2024. "LSTM (Long Short Term Memory)", 2024.
- Mukmin, D. A., Irsyada, R., dkk. 2022. "Penerapan Metode Moving Average Pada Sistem Informasi Prediksi Angka Kemiskinan".

Multidisciplinary Applications of Quantum Information Science (Al-Mantiq), 1(1).

<https://doi.org/10.32665/almantiq.v1i1.330>.

Nurhambali, M. R., Angraini, Y., dkk. 2024. "Implementation of Long Short-Term Memory for Gold Prices Forecasting". **Malaysian Journal of Mathematical Sciences**, 18(2), 399–422.

<https://doi.org/10.47836/mjms.18.2.11>.

Park, M. J., dan Yang, H. S. 2024. "Comparative Study of Time Series Analysis Algorithms Suitable for Short-Term Forecasting in Implementing Demand Response Based on AMI". **Sensors**, 24(22). <https://doi.org/10.3390/s24227205>.

Pimentel, K. B. A., Oliveira, R. S., dkk. 2024. "Prediction of visceral leishmaniasis incidence using the Seasonal Autoregressive Integrated Moving Average model (SARIMA) in the state of Maranhão, Brazil". **Brazilian Journal of Biology**, 84.

<https://doi.org/10.1590/1519-6984.257402>.

Pujjarini, E. H., dan Damayanti, A. 2025. "Hybrid ARIMA-LSTM Model for Gold Price Forecasting at Pegadaian 1 Corresponding Author", 9(3), 1098–1108.

<https://doi.org/10.30829/zero.v9i3.25962>.

PUTRI, N. W., SUMARJAYA, I. W., dkk. 2021. "PENERAPAN METODE BAYESIAN VECTOR AUTOREGRESSION DALAM PERAMALAN JUMLAH KUNJUNGAN WISATAWAN CINA KE BALI". **E-Jurnal Matematika**, 10(2).

<https://doi.org/10.24843/mtk.2021.v10.i02.p326>.

Singh, Dr. N. P., Meitei, I. L., dkk. 2024. "Comparative Analysis Of Arima, Sarima And Ets Models For Forecasting Monthly Precipitation In Manipur, India Using High-Resolution Satellite Data". **International Journal of Environmental Sciences**.

<https://doi.org/10.64252/6trm1536>.

Sirisha, U. M., Belavagi, M. C., dkk. 2022. "Profit Prediction Using ARIMA, SARIMA and LSTM Models in Time Series Forecasting: A Comparison". **IEEE Access**, 10.

<https://doi.org/10.1109/ACCESS.2022.3224938>.

- Tegar, R., Hari, P., dkk. 2026. "Indonesian Gold Price Forecasting Using Simple and Stacked LSTM with Expanding Window", *10*(1), 406–416.
- Vita, N., dan Wulandari, O. A. D. 2025. "Konstruksi Makna Emas sebagai Aset Safe Haven di Era Perang Dagang Amerika Serikat dan China: Studi Fenomenologi Investor Ritel Indonesia". **Jurnal Witana**, *3*(2), 1–13. diambil dari <https://jurnalwitana.com/index.php/jw/article/view/111>.
- Wahyu, D., Ade, C., dkk. 2025. "Peran Budgeting dan Forecasting dalam Meningkatkan Efisiensi Keuangan Perusahaan". **Seminar Nasional & Call for Paper HUBISINTEK 2024**, *5*(1), 731–737.
- Widiputra, H., Mailangkay, A., dkk. 2021. "Prediksi Indeks BEI dengan Ensemble Convolutional Neural Network dan Long Short-Term Memory". **Jurnal RESTI**, *5*(3). <https://doi.org/10.29207/resti.v5i3.3111>.
- Wizsa, U. A., Rahayu, W. D., dkk. 2022. "FORECASTING OF INDONESIA'S POST-COVID-19 EXPORT VALUE USING SARIMA". **Jurnal Statistika Universitas Muhammadiyah Semarang**, *10*(2). <https://doi.org/10.26714/jsunimus.10.2.2022.13-24>.
- Wu, D. C. W., Ji, L., dkk. 2021. "Forecasting Tourist Daily Arrivals With A Hybrid Sarima–Lstm Approach". **Journal of Hospitality and Tourism Research**, *45*(1). <https://doi.org/10.1177/1096348020934046>.
- Xian, X., Wang, L., dkk. 2023. "Comparison of SARIMA model, Holt-winters model and ETS model in predicting the incidence of foodborne disease". **BMC Infectious Diseases**, *23*(1). <https://doi.org/10.1186/s12879-023-08799-4>.

BIODATA PENULIS



Nama : I Nyoman Bagus Aditya Adnyana
Alamat : Br.Mulukbabi Desa Sangeh, Kec.
Abiansemal, Kab. Badung
TTL : Sangeh, 22 Mei 2005
Telepon : 081337150426
Email : bagusadityaadnyana@gmail.com
Angkatan : 2023
Moto : Kadang Hidup Kadang Tidak

Latar Belakang Pendidikan :

2011 – 2017 : SD 3 Sangeh
2017 – 2019 : SMP Negeri 1 Abiansemal
2019 – 2023 : SMA Negeri 1 Abiansemal
2023 – Sekarang : Institut Bisnis dan Teknologi Indonesia

Pengalaman Organisasi :

2023 : Anggota Panitia Techfest

Pengalaman Kerja :

2021 – 2023 : Bekerja di Ahass UD Danau Sari Motor Sangeh, sebagai pengelolaan gudang.
2024 : Locus *Event Team* 2024 sebagai *Runner*, Bertanggung jawab penuh dalam mendukung kelancaran taktis acara melalui mobilisasi kebutuhan logistik
2024 : Nuanu Night sebagai Station Crew Standby di pos venue spesifik untuk melayani aktivitas interaktif pengunjung
2025 : Nuanu Run sebagai Runner Mendukung kelancaran operasional lomba lari dengan mengamankan logistik rute, mengelola pasokan di water station, area pendaftaran, serta merespons kebutuhan taktis tim medis di lapangan.

- 2025 : Nuanu Fun Run sebagai Runner Bertindak sebagai kru pendukung yang responsif dalam mempersiapkan area race village, mendistribusikan race pack peserta, serta memasang barikade keamanan di area publik.
- 2025 : Genius Future Summit sebagai Runner Mendukung kelancaran teknis konferensi melalui pengelolaan logistik mikro seperti penyediaan materi seminar, perlengkapan mikrofon pembicara, serta kebutuhan taktis di area panggung
- 2025 : OPPO RUN 2025 Sebagai Runner logistik, mengoordinasikan manajemen logistik skala besar meliputi inventarisasi barang masuk-keluar, pengangkutan material lomba, serta pendistribusian suplai kebutuhan kru di seluruh pos lapangan.